



Desain Pengklasifikasi Citra Kuantum dengan Skema *Data Re-uploading Quantum* *Convolution* dan *Data Re-uploading Classifier*

Eraraya Ricardo Muten

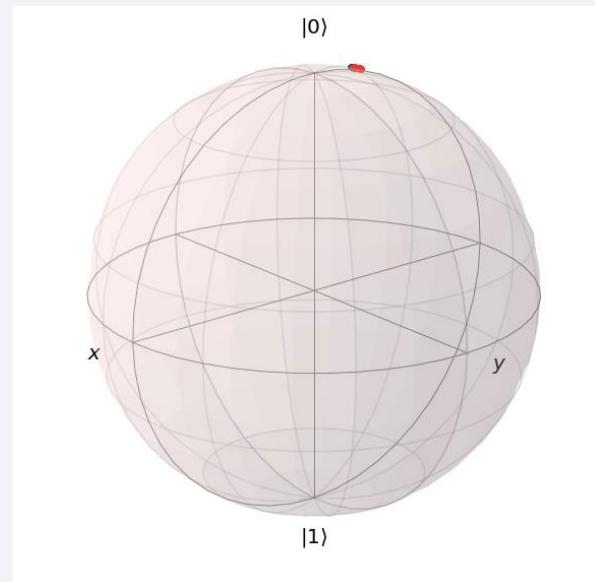
Program Studi Teknik Fisika

Laboratorium Teknologi Kuantum

Institut Teknologi Bandung

Pembimbing: Ir. Nugraha, Ph.D.

Prof. Andriyan Bayu Suksmono M.T., Ph.D.



github.com/eraraya-ricardo/quantum_image_classifier

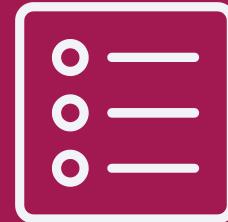
Pendahuluan

Dasar Komputasi Kuantum

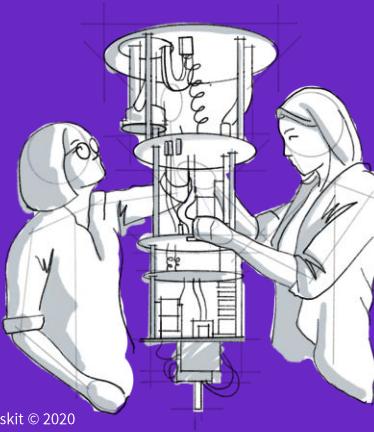
Rancangan Desain

Hasil dan Pembahasan

Kesimpulan dan Saran



Outline Presentasi



A black and white line drawing of two scientists in lab coats and safety glasses working on a large, complex apparatus. One scientist is standing and reaching up, while the other is crouching down. The apparatus has various glass components, tubes, and a central cylindrical structure.

Qiskit © 2020

Pendahuluan

- Latar Belakang
- Tujuan Penelitian
- Penelitian Terkait
- Kebaruan Penelitian

Latar Belakang

01

Resiko stagnasi
Hukum Moore dan
bertambahnya
kebutuhan
komputasi^[1]

02

Komputasi Kuantum
berpotensi
meningkatkan
performa komputasi,
termasuk dalam
pembelajaran mesin
dan pengolahan
data^[2]

03

Perkembangan
komputasi kuantum
pesat namun
perangkat keras saat
ini masih terbatas
*Noisy Intermediate
Scale Quantum*
(NISQ)^[3]

04

Algoritma Kuantum
Variasional (AKV)
menjadi strategi
andalan dalam era
NISQ untuk aplikasi –
aplikasi tertentu^[4]

Tujuan Penelitian

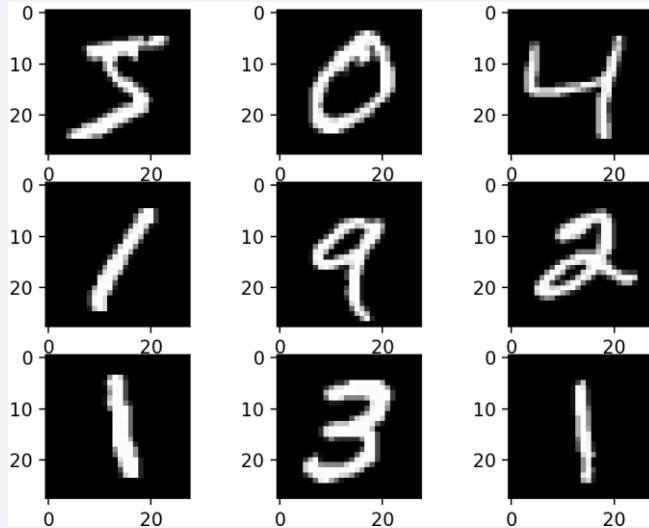
Kondisi Saat Ini

AKV telah dimanfaatkan dalam beberapa penelitian sebelumnya untuk aplikasi klasifikasi biner untuk citra MNIST namun akurasi yang dihasilkan relatif masih rendah.

Tujuan Penelitian

Merancang pengklasifikasi citra angka tulisan tangan “MNIST^[5]” (keabuan berdimensi 28 x 28) dengan komputasi kuantum berbasis metode AKV dengan target:

1. Algoritma dalam skala NISQ
2. Mencapai akurasi klasifikasi biner yang lebih baik dari penelitian terkait sebelumnya
3. Algoritma dapat diekspansi ke klasifikasi banyak kelas



Penelitian Terkait

E. Farhi dan H. Neven.
Classification with Quantum Neural Networks on Near Term Processors.
Google AI
Quantum. Agustus 2018.^[6]

Dimensi citra direduksi dengan metode interpolasi bilinear dari 28x28 jadi 4x4.

Klasifikasi biner menggunakan

- lebih dari 6000 sampel data latih
- 17 qubit
- 32 parameter

Akurasi latih 0,88 dan akurasi uji 0,9.

Tidak melakukan ekspansi klasifikasi banyak kelas.

Skolik, et al.
Layerwise learning for quantum neural networks.
Volkswagen Data:Lab. Januari 2021.^[7]

Dimensi citra direduksi dengan PCA, menggunakan 10 komponen prinsip. Arsitektur klasifikasi biner membutuhkan 1 qubit tiap komponen prinsip = 10 qubit. Akurasi uji 0,73. Tidak melakukan ekspansi klasifikasi banyak kelas.

S. Mardirosian.
Quantum-enhanced Supervised Learning with Variational Quantum Circuits.
Leiden University. Juli 2019.^[8]

Dimensi citra direduksi dengan PCA, menggunakan 2 & 3 komponen prinsip. Arsitektur klasifikasi biner membutuhkan 1 qubit tiap komponen prinsip = 2 & 3 qubit. Akurasi latih 0,96 dan uji 0,89 (2 qubit), akurasi latih 0,97 dan uji 0,90 (3 qubit). Tidak melakukan ekspansi klasifikasi banyak kelas.

Kebaruan Penelitian

Penelitian ini tidak hanya mengimplementasikan algoritma kuantum dan skema – skema yang sudah ada, namun juga melakukan modifikasi perbaikan dan pengajuan skema baru.

Modifikasi skema pengklasifikasi kuantum *Data*



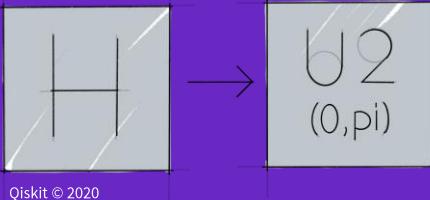
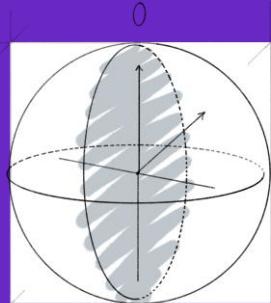
Re-uploading Classifier(DRC)^[9]

Modifikasi skema DRC menjadi *Data Re-uploading Classifier* dengan Representasi Biner (DRC-RB) yang meningkatkan akurasi klasifikasi banyak kelas.

Mengajukan skema konvolusi citra dengan sirkuit kuantum



Mengajukan skema *Data Re-uploading Quantum Convolution* (DRQConv), yaitu skema konvolusi citra dengan sirkuit kuantum yang terinspirasi dari lapisan konvolusi pada Jaringan Saraf Tiruan Konvolusi.



Qiskit © 2020

Dasar Komputasi Kuantum

- Qubit dan *Bloch Sphere*
- Gerbang dan Sirkuit Kuantum
- Pengukuran Nilai Ekspektasi

Qubit dan Bloch Sphere

- Qubit: elemen komputasi terkecil dalam komputer kuantum.
- Secara fisis: sistem mekanika kuantum dengan dua keadaan kuantum misalnya spin elektron (up & down), atau polarisasi foton (vertikal & horizontal).

- Secara matematis: dua basis vektor keadaan pada ruang Hilbert yang ortonormal.

$$|0\rangle = \begin{bmatrix} 1 \\ 0 \end{bmatrix}, \quad |1\rangle = \begin{bmatrix} 0 \\ 1 \end{bmatrix}$$

- Keadaan gabungan 2 atau lebih qubit dihitung dengan perkalian tensor.

$$|01\rangle = |0\rangle \otimes |1\rangle = \begin{bmatrix} 1 \\ 0 \end{bmatrix} \otimes \begin{bmatrix} 0 \\ 1 \end{bmatrix} = \begin{bmatrix} 0 \\ 1 \\ 0 \\ 0 \end{bmatrix}$$

- Dua fitur yang membuat qubit berbeda dari bit klasik:
1. Superposisi: qubit dapat berada dalam dua keadaan sekaligus dalam waktu yang sama, α dan β adalah amplitudo keadaan kuantum

$$|\Psi\rangle = \alpha|0\rangle + \beta|1\rangle$$

$$|\alpha|^2 + |\beta|^2 = 1$$

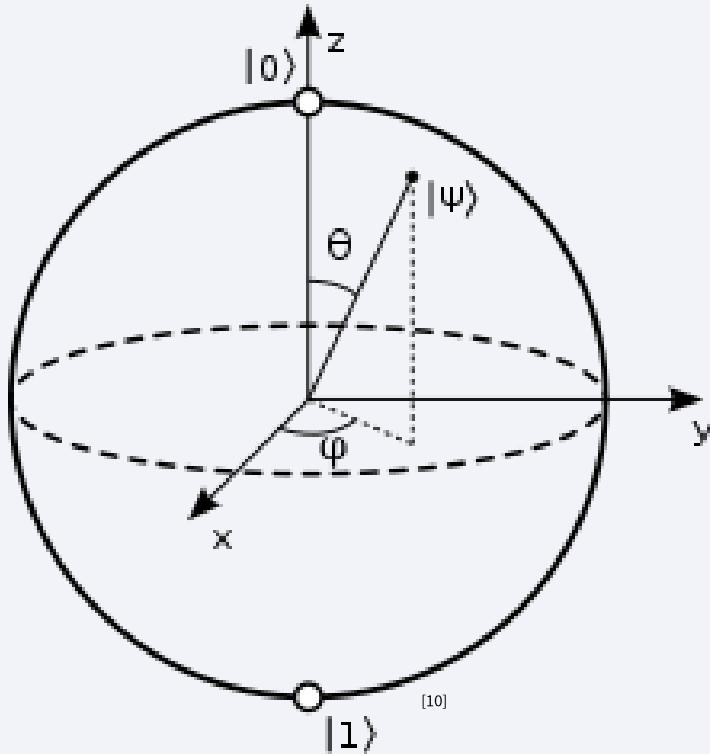
2. *Entanglement*: peristiwa ketika $N \geq 2$ qubit berinteraksi membentuk $|\Psi_{ent}\rangle$ yang tidak dapat difaktorisasi ke dalam keadaan kuantum yang terpisah, tidak ada pasangan

$$\{|Q_1\rangle, |Q_2\rangle, \dots, |Q_N\rangle\} \in \{|0\rangle, |1\rangle\}$$

yang memenuhi

$$|\Psi_{ent}\rangle = |Q_1\rangle \otimes |Q_2\rangle \otimes \cdots \otimes |Q_N\rangle$$

Qubit dan Bloch Sphere



$$|\psi\rangle = \cos\left(\frac{\theta}{2}\right)|0\rangle + e^{i\phi} \sin\left(\frac{\theta}{2}\right)|1\rangle$$

Gerbang dan Sirkuit Kuantum

- Analog dengan komputer klasik, komputer kuantum juga menggunakan gerbang operasi untuk mengontrol & mengubah keadaan qubit. Proses perubahan keadaan kuantum qubit dengan gerbang kuantum disebut evolusi unitari.

- Secara matematis: perkalian suatu matriks unitari dengan vektor keadaan qubit.

- Gebang kuantum dapat bekerja pada 1 atau lebih qubit.

- Contoh operasi gerbang Hadamard pada 1 qubit:

$$H|0\rangle = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix} \begin{bmatrix} 1 \\ 0 \end{bmatrix} = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \end{bmatrix} = \frac{1}{\sqrt{2}} |0\rangle + \frac{1}{\sqrt{2}} |1\rangle$$

- Contoh operasi gerbang CNOT pada 2 qubit:

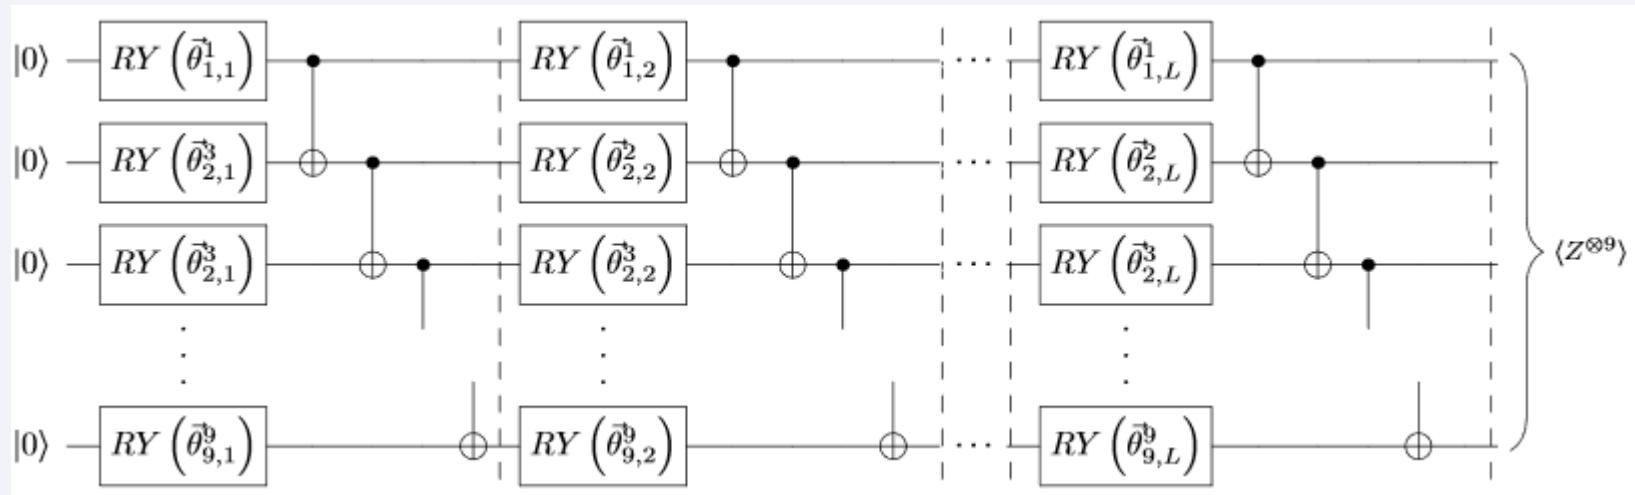
$$CNOT |10\rangle = CNOT (|1\rangle \otimes |0\rangle) = \begin{bmatrix} 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 0 & 1 \\ 0 & 0 & 1 & 0 \end{bmatrix} \begin{bmatrix} 0 \\ 1 \\ 0 \\ 0 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \\ 0 \\ 1 \end{bmatrix} = \begin{bmatrix} 0 \\ 1 \\ 0 \\ 0 \end{bmatrix} \otimes \begin{bmatrix} 0 \\ 1 \\ 0 \\ 0 \end{bmatrix} = |11\rangle$$

Operator	Gate(s)	Matrix
Pauli-X (X)		$\begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix}$
Pauli-Y (Y)		$\begin{bmatrix} 0 & -i \\ i & 0 \end{bmatrix}$
Pauli-Z (Z)		$\begin{bmatrix} 1 & 0 \\ 0 & -1 \end{bmatrix}$
Hadamard (H)		$\frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix}$
Phase (S, P)		$\begin{bmatrix} 1 & 0 \\ 0 & i \end{bmatrix}$
$\pi/8$ (T)		$\begin{bmatrix} 1 & 0 \\ 0 & e^{i\pi/4} \end{bmatrix}$
Controlled Not (CNOT, CX)		$\begin{bmatrix} 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 0 & 1 \\ 0 & 0 & 1 & 0 \end{bmatrix}$
Controlled Z (CZ)		$\begin{bmatrix} 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & -1 \end{bmatrix}$
SWAP		$\begin{bmatrix} 1 & 0 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 0 & 1 \end{bmatrix}$
Toffoli (CCNOT, CCX, TOFF)		$\begin{bmatrix} 1 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 1 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 1 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 1 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 1 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0 & 1 \\ 0 & 0 & 0 & 0 & 0 & 0 & 1 & 0 \end{bmatrix}$
[11]		

Gerbang dan Sirkuit Kuantum

$$RY(\phi) = e^{-\frac{i\phi\sigma_y}{2}} = \begin{bmatrix} \cos\left(\frac{\phi}{2}\right) & -\sin\left(\frac{\phi}{2}\right) \\ \sin\left(\frac{\phi}{2}\right) & \cos\left(\frac{\phi}{2}\right) \end{bmatrix}$$

$$R(\phi, \theta, \omega) = \begin{bmatrix} e^{-i(\phi+\omega)/2}\cos(\theta/2) & -e^{i(\phi-\omega)/2}\sin(\theta/2) \\ e^{-i(\phi-\omega)/2}\sin(\theta/2) & e^{i(\phi+\omega)/2}\cos(\theta/2) \end{bmatrix}$$



Pengukuran Nilai Ekspektasi

- Setelah proses komputasi dilakukan, hasil komputasi diperoleh dengan mengukur qubit yang terlibat.
- Karena superposisi dan *entanglement*, pengukuran qubit dengan keadaan kuantum yang sama dapat menghasilkan pengukuran yang berbeda. Distribusi probabilitas pengukuran ini ditentukan oleh amplitudo keadaan kuantum.

- Oleh karena itu pengukuran dilakukan beberapa kali dan hasil pengukuran merupakan estimasi nilai ekspektasi

$$\lambda = \langle \Psi | O | \Psi \rangle = \langle O \rangle$$

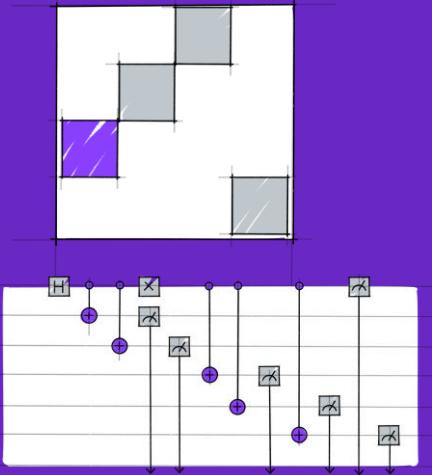
- Pengukuran keadaan kuantum dari qubit dilakukan dengan *observable* Hermitian tertentu. *Observable* dapat berupa gerbang kuantum atau matriks Hermitian unitari.
- Contoh pengukuran dengan *observable* gerbang Pauli Z

$$|\Psi\rangle = \alpha|0\rangle + \beta|1\rangle$$

$$\langle Z \rangle = \langle \Psi | Z | \Psi \rangle = (\alpha^*[1 \ 0] + \beta^*[0 \ 1]) \begin{bmatrix} 1 & 0 \\ 0 & -1 \end{bmatrix} \left(\alpha \begin{bmatrix} 1 \\ 0 \end{bmatrix} + \beta \begin{bmatrix} 0 \\ 1 \end{bmatrix} \right) = |\alpha|^2 - |\beta|^2$$

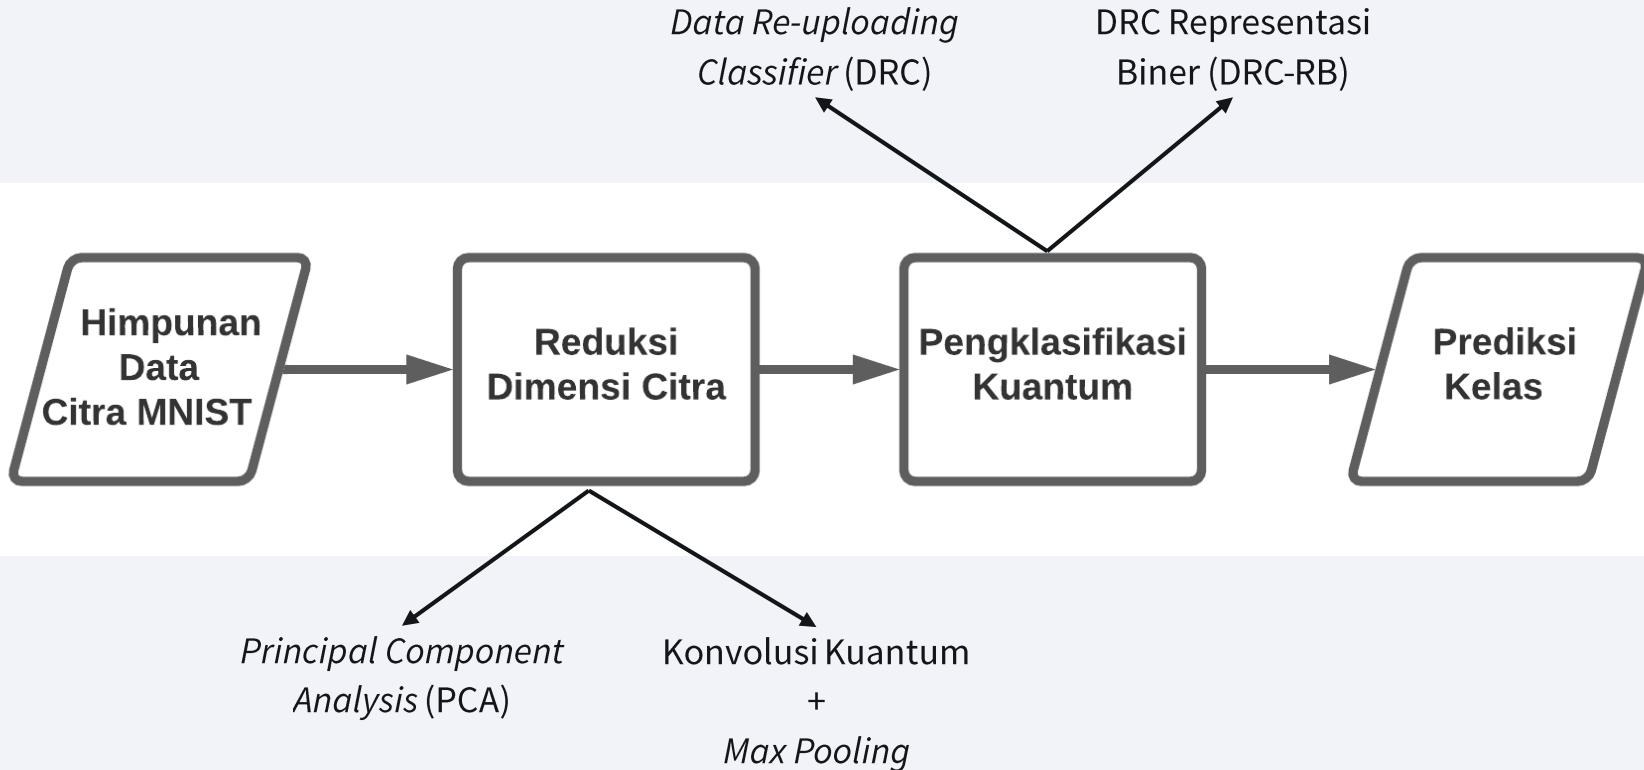
Rancangan Desain

- Aliran Data
- Pengklasifikasi Kuantum
- Metode Reduksi Dimensi
- Daftar Skema yang Diuji

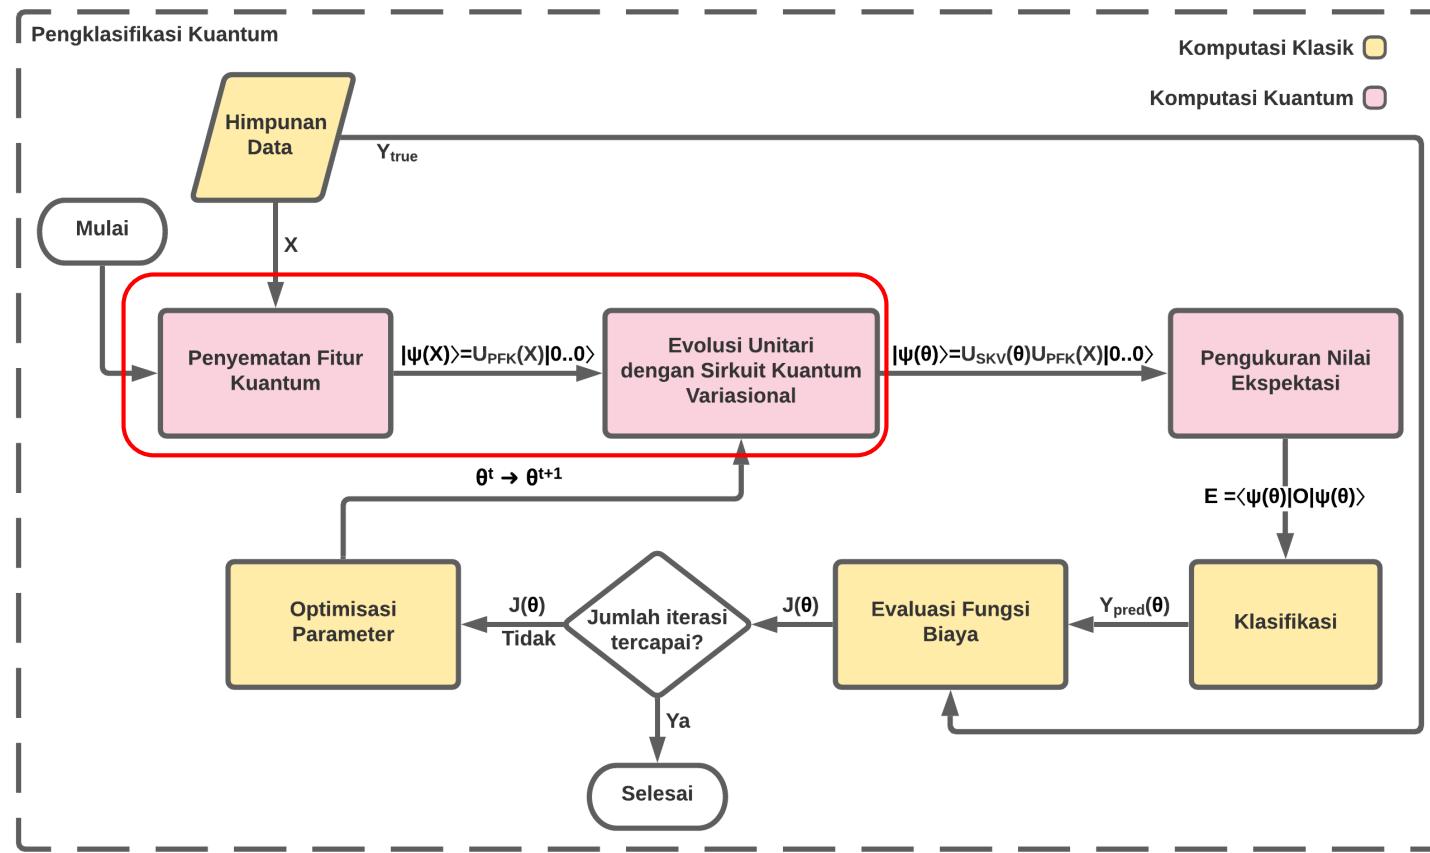


Qiskit © 2020

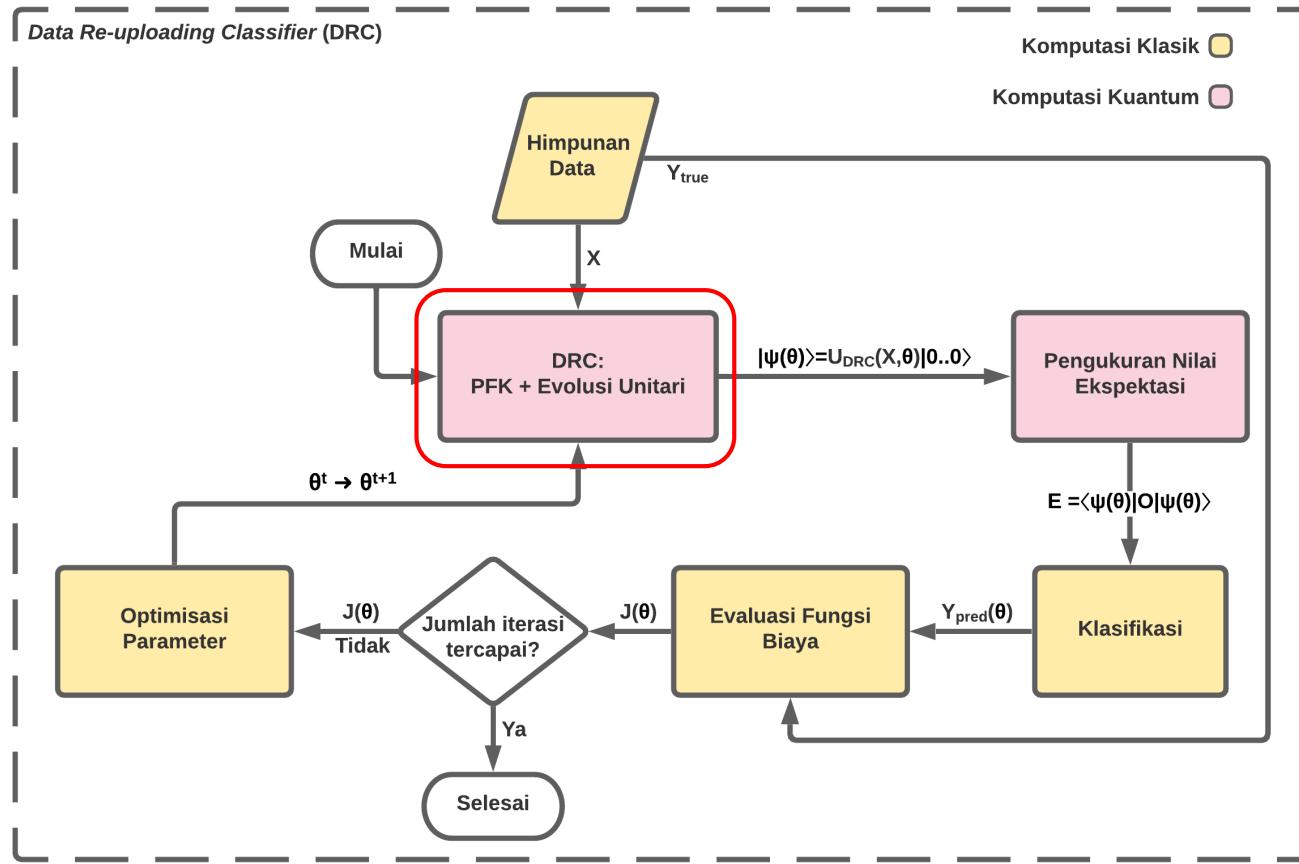
Aliran Data



Pengklasifikasi Kuantum: Umum



Pengklasifikasi Kuantum: DRC



Skema *Data Re-uploading Classifier (DRC)*^[9] menyatukan tahap penyematkan fitur dan operasi unitari dalam satu sirkuit yang sama.

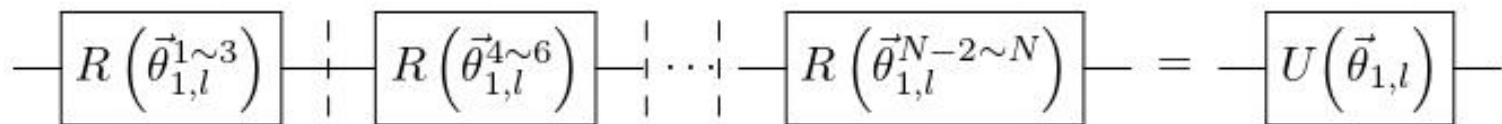
Pengklasifikasi Kuantum: DRC

DRC: Fitur sampel data (x) dan parameter bobot (w) & bias (b) dimasukan ke dalam 1 sirkuit yang sama.

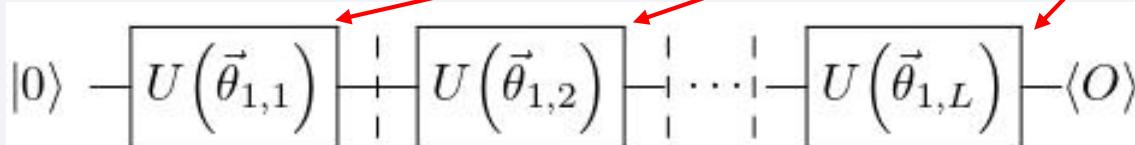
Kata “data re-uploading” digunakan karena penyematan sampel data ke sirkuit kuantum diulangi beberapa kali.

$$\vec{\theta}_{q,l}^{n \sim n+2} = (\theta_{q,l}^n, \theta_{q,l}^{n+1}, \theta_{q,l}^{n+2})$$

$$\theta_{q,l}^n = w_{q,l}^n x^n + b_{q,l}^n$$



Skematik sirkuit 1 Lapis Sirkuit DRC dengan 1 qubit



Skematik beberapa Lapis Sirkuit DRC

Pengklasifikasi Kuantum: DRC

Contoh *observable* dan label kelas untuk kasus klasifikasi 4 kelas dengan DRC

Keadaan kuantum representasi tiap label dipilih yang memaksimalkan ortogonalitas:

$$|\Psi_0\rangle = |0\rangle = \begin{bmatrix} 1 \\ 0 \end{bmatrix}$$

$$|\Psi_1\rangle = \begin{bmatrix} 0,577350 \\ 0,816497 \end{bmatrix}$$

$$|\Psi_2\rangle = \begin{bmatrix} 0,288675 - 0,50j \\ 0,408248 + 0,707107j \end{bmatrix}$$

$$|\Psi_3\rangle = \begin{bmatrix} 0,288675 + 0,50j \\ 0,408248 - 0,707107j \end{bmatrix}$$

Observable untuk mengukur fidelitas:

$$O_0 = |\Psi_0\rangle\langle\Psi_0|$$

$$O_1 = |\Psi_1\rangle\langle\Psi_1|$$

$$O_2 = |\Psi_2\rangle\langle\Psi_2|$$

$$O_3 = |\Psi_3\rangle\langle\Psi_3|$$

Vektor keluaran DRC untuk sampel data ke-m:

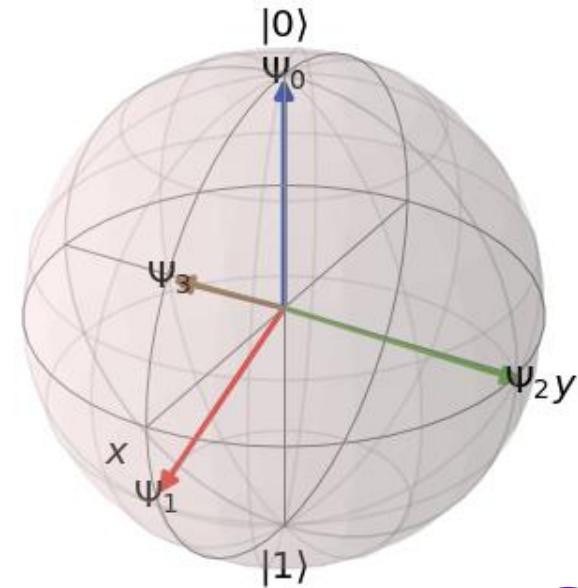
$$\vec{y}_{pred_m} = \begin{bmatrix} \alpha_0\langle O_0 \rangle \\ \alpha_1\langle O_1 \rangle \\ \alpha_2\langle O_2 \rangle \\ \alpha_3\langle O_3 \rangle \end{bmatrix}$$

Vektor representasi tiap label:

$$\vec{y}_0 = \begin{bmatrix} \langle \Psi_0 | O_0 | \Psi_0 \rangle \\ \langle \Psi_0 | O_1 | \Psi_0 \rangle \\ \langle \Psi_0 | O_2 | \Psi_0 \rangle \\ \langle \Psi_0 | O_3 | \Psi_0 \rangle \end{bmatrix} = \begin{bmatrix} 1 \\ 1/3 \\ 1/3 \\ 1/3 \end{bmatrix}, \quad \vec{y}_1 = \begin{bmatrix} 1/3 \\ 1 \\ 1/3 \\ 1/3 \end{bmatrix},$$

$$\vec{y}_2 = \begin{bmatrix} 1/3 \\ 1/3 \\ 1 \\ 1/3 \end{bmatrix}, \quad \vec{y}_3 = \begin{bmatrix} 1/3 \\ 1/3 \\ 1/3 \\ 1 \end{bmatrix}$$

Visualisasi *Bloch Sphere* keadaan kuantum tiap label:



Pengklasifikasi Kuantum: DRC-RB

Salah satu kelemahan DRC adalah semakin menyempitnya area *Bloch Sphere* untuk tiap kelas seiring bertambahnya jumlah kelas

Sirkuit menggunakan $\log_2 C$ qubit dan label kelas dinyatakan dalam bentuk biner. Tiap qubit berperan hanya sebagai pengklasifikasi biner.

Kelebihan DRC Representasi Biner (DRC-RB):
Optimizer lebih mudah mencari parameter optimum.

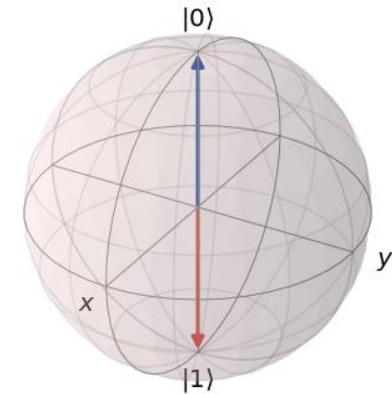
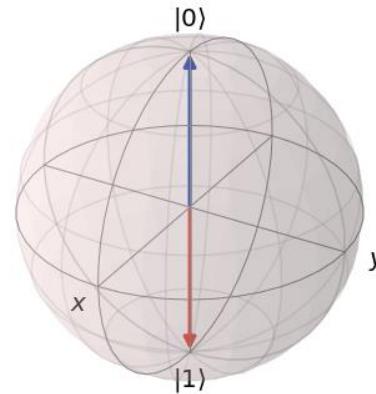
Untuk 4 kelas, perlu 2 qubit dengan label:

$$\begin{aligned}\text{label 0} &\rightarrow |0\rangle|0\rangle \\ \text{label 1} &\rightarrow |0\rangle|1\rangle \\ \text{label 2} &\rightarrow |1\rangle|0\rangle \\ \text{label 3} &\rightarrow |1\rangle|1\rangle\end{aligned}$$

Hanya perlu menggunakan 2 observable

$$\begin{aligned}O_0 &= |0\rangle\langle 0| = \begin{bmatrix} 1 & 0 \\ 0 & 0 \end{bmatrix} \\ O_1 &= |1\rangle\langle 1| = \begin{bmatrix} 0 & 0 \\ 0 & 1 \end{bmatrix}\end{aligned}$$

Visualisasi *Bloch Sphere* keadaan kuantum (2 qubit):



Metode Reduksi Dimensi: PCA

Principal Component Analysis (PCA): teknik reduksi dimensi/fitur dengan memproyeksikan data ke arah yang memaksimalkan variansi fitur dan membuat kovariansi antar fitur menjadi nol

PCA mencari kombinasi linear dari fitur-fitur himpunan data X dengan variansi maksimum^[12] dan menghasilkan fitur baru yang disebut komponen prinsip

Grafik nilai EV untuk 100 komponen prinsip pertama hasil transformasi data MNIST 2 kelas



$$EV = \frac{\sigma_i^2}{\sum_{j=1}^N \sigma_j^2} \times 100\%$$

Metode Reduksi Dimensi: Konvolusi Klasik

0	0	0	0	0	0	...
0	156	155	156	158	158	...
0	153	154	157	159	159	...
0	149	151	155	158	159	...
0	146	146	149	153	158	...
0	145	143	143	148	158	...
...

Input Channel #1 (Red)

0	0	0	0	0	0	...
0	167	166	167	169	169	...
0	164	165	168	170	170	...
0	160	162	166	169	170	...
0	156	156	159	163	168	...
0	155	153	153	158	168	...
...

Input Channel #2 (Green)

0	0	0	0	0	0	...
0	163	162	163	165	165	...
0	160	161	164	166	166	...
0	156	158	162	165	166	...
0	155	155	158	162	167	...
0	154	152	152	157	167	...
...

Input Channel #3 (Blue)

-1	-1	1
0	1	-1
0	1	1

Kernel Channel #1



308

+

1	0	0
1	-1	-1
1	0	-1

Kernel Channel #2



-498

0	1	1
0	1	0
1	-1	1

Kernel Channel #3



164 + 1 = -25

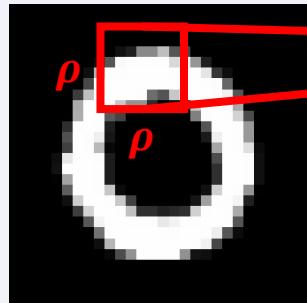
Bias = 1

-25				...
				...
				...
				...
				...

Output

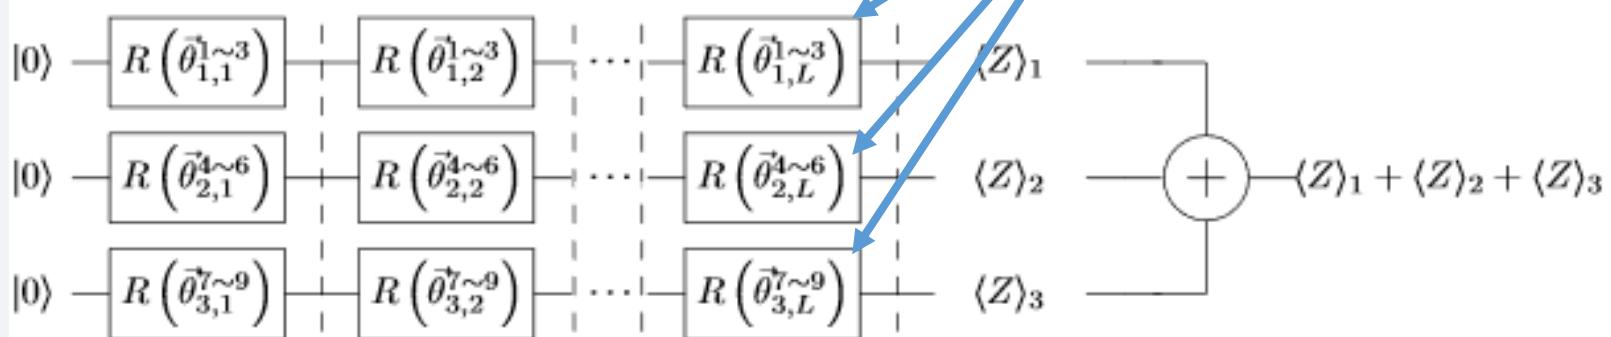
Metode Reduksi Dimensi: Konvolusi Kuantum

Pada penelitian ini diajukan skema *Data Re-uploading Quantum Convolution (DRQConv)*: sekma konvolusi citra dengan sirkuit kuantum variasional



$$\vec{x} = (x^1, x^2, \dots, x^\zeta), \quad \rho \times \rho = 3 \times 3, \quad \zeta = 9$$

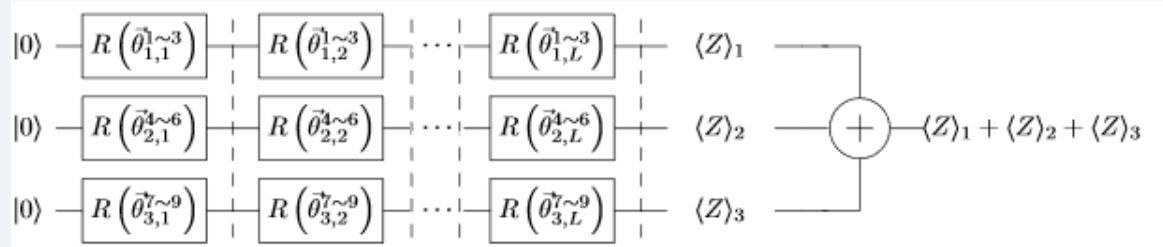
$$\theta_{q,l}^n = w_{q,l}^n x^n + b_{q,l}^n \rightarrow \vec{\theta}_{q,l}^{n \sim n+2} = (\theta_{q,l}^n, \theta_{q,l}^{n+1}, \theta_{q,l}^{n+2})$$



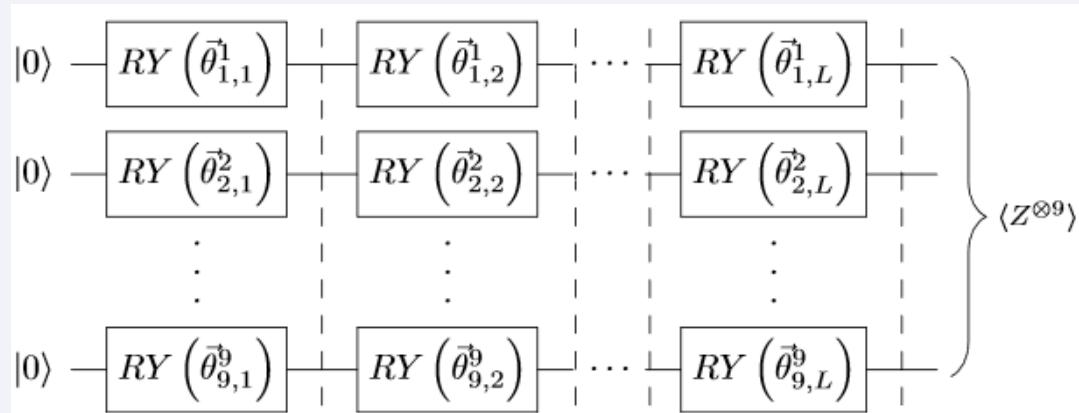
Metode Reduksi Dimensi: Konvolusi Kuantum

Dilakukan uji coba dengan 3 ansatz (arsitektur tebakan) sirkuit berbeda:

1. DRQConv I



2. DRQConv II

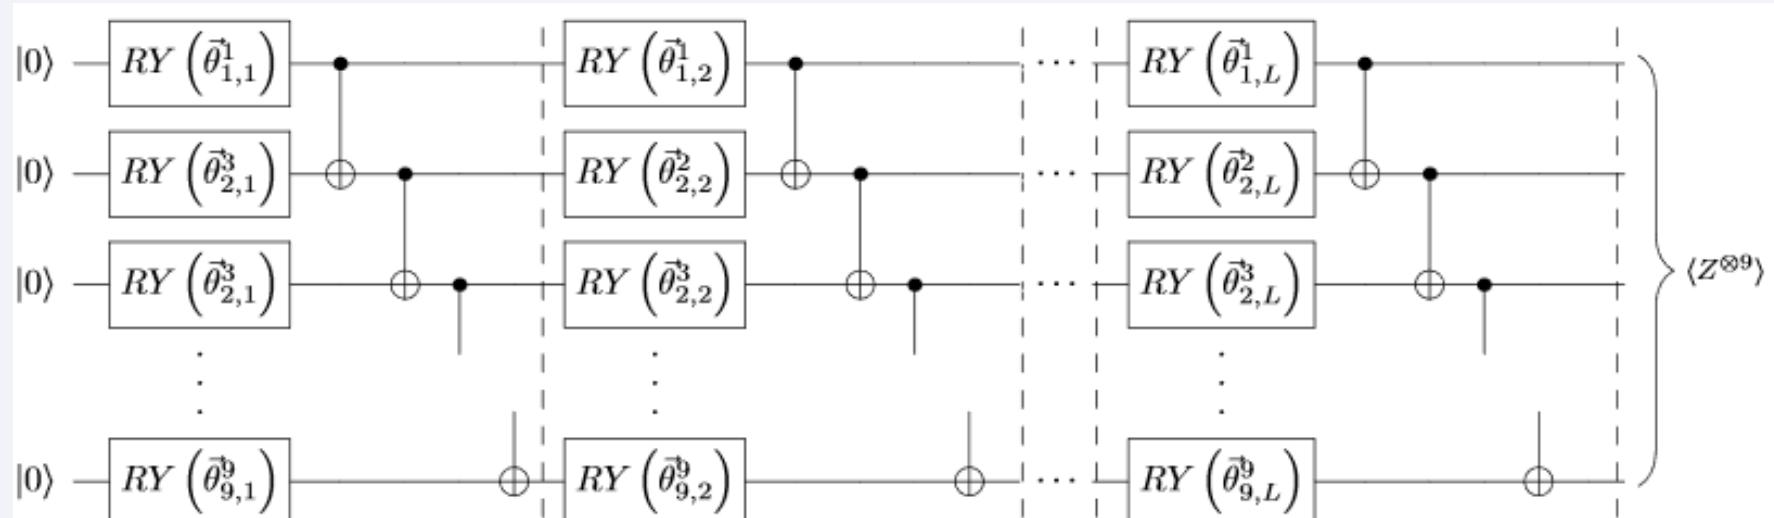


$$Z^{\otimes 9} = \underbrace{Z \otimes Z \otimes \cdots \otimes Z}_9$$

Metode Reduksi Dimensi: Konvolusi Kuantum

Dilakukan uji coba dengan 3 ansatz (arsitektur tebakan) sirkuit berbeda:

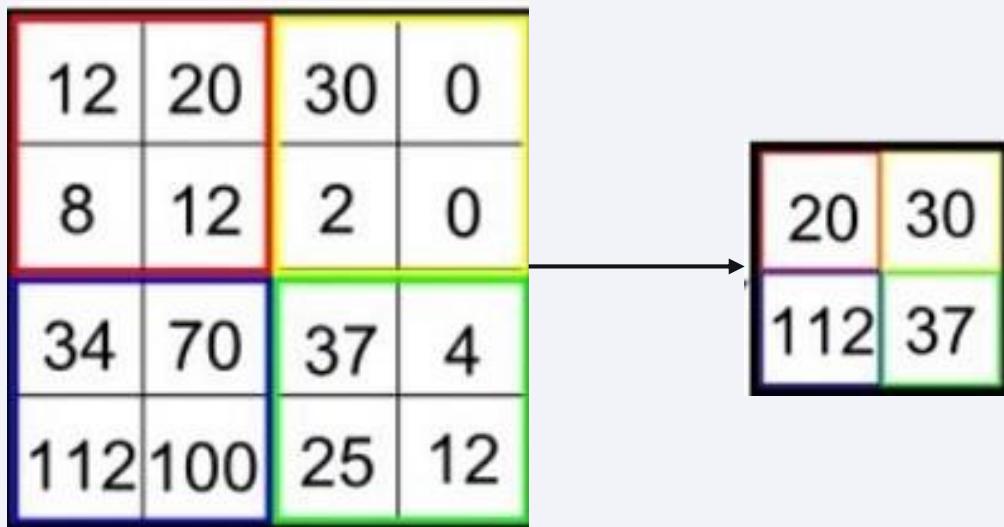
3. DRQConv II dengan *Entanglement*



$$Z^{\otimes 9} = \underbrace{Z \otimes Z \otimes \cdots \otimes Z}_9$$

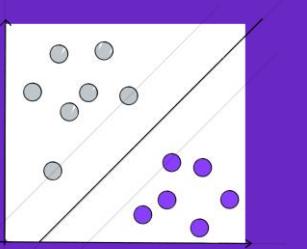
Metode Reduksi Dimensi: *Max Pooling*

Setelah dikonvolusi dengan sirkuit kuantum, citra kemudian dilewatkan ke *max pooling*

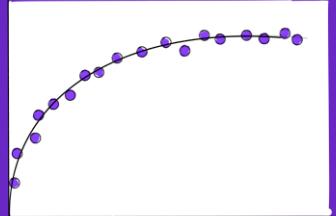


Daftar Skema yang Diuji

1. Pengklasifikasi DRC dengan Reduksi PCA
 - 2 Kelas (Angka 0 & 1)
 - 4 Kelas (Angka 0, 1, 2, 3)
2. Pengklasifikasi DRC-RB dengan Reduksi PCA
 - 4 Kelas (Angka 0, 1, 2, 3)
 - 8 Kelas (Angka 0 – 7)
3. Pengklasifikasi DRC-RB dengan Reduksi Konvolusi Kuantum (DRQConv)
 - 2 Kelas (Angka 0 & 1)
 - 4 Kelas (Angka 0, 1, 2, 3)

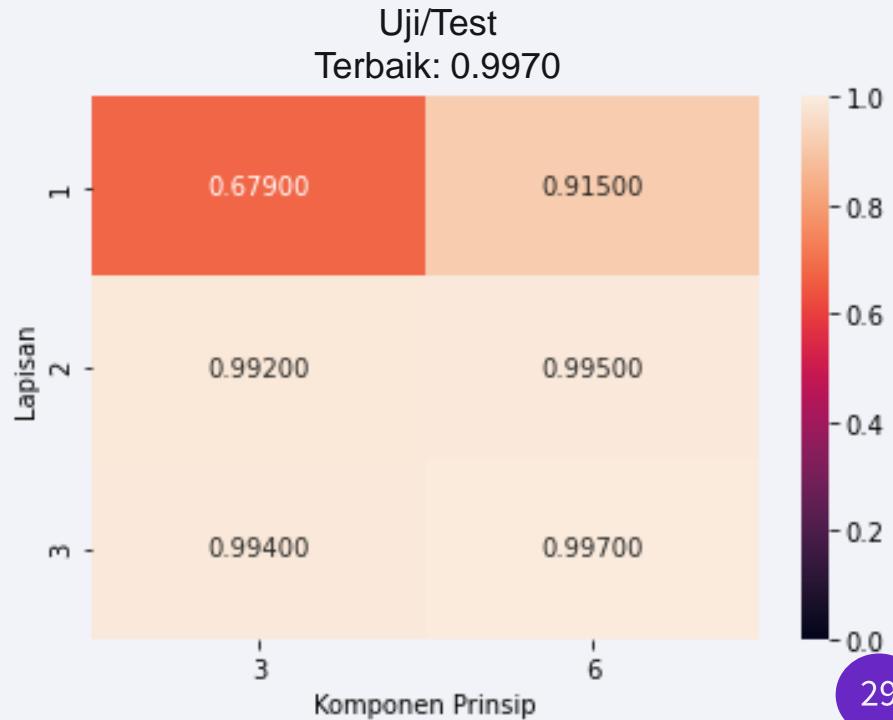
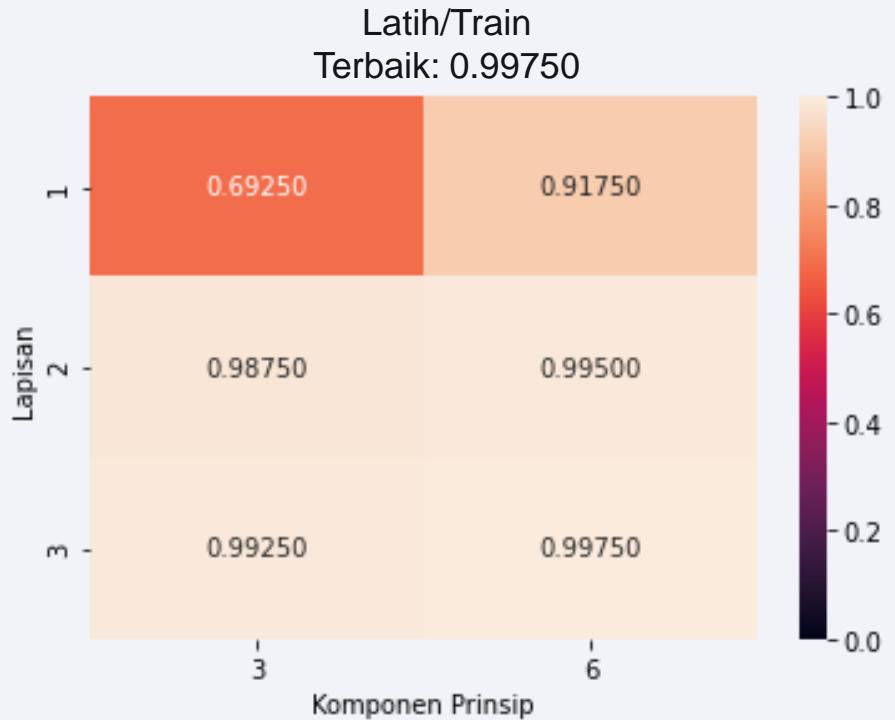


Hasil dan Pembahasan

- 
- Pengklasifikasi DRC dengan Reduksi PCA
 - Pengklasifikasi DRC-RB dengan Reduksi PCA
 - Pengklasifikasi DRC-RB dengan Reduksi Konvolusi Kuantum (DRQConv)

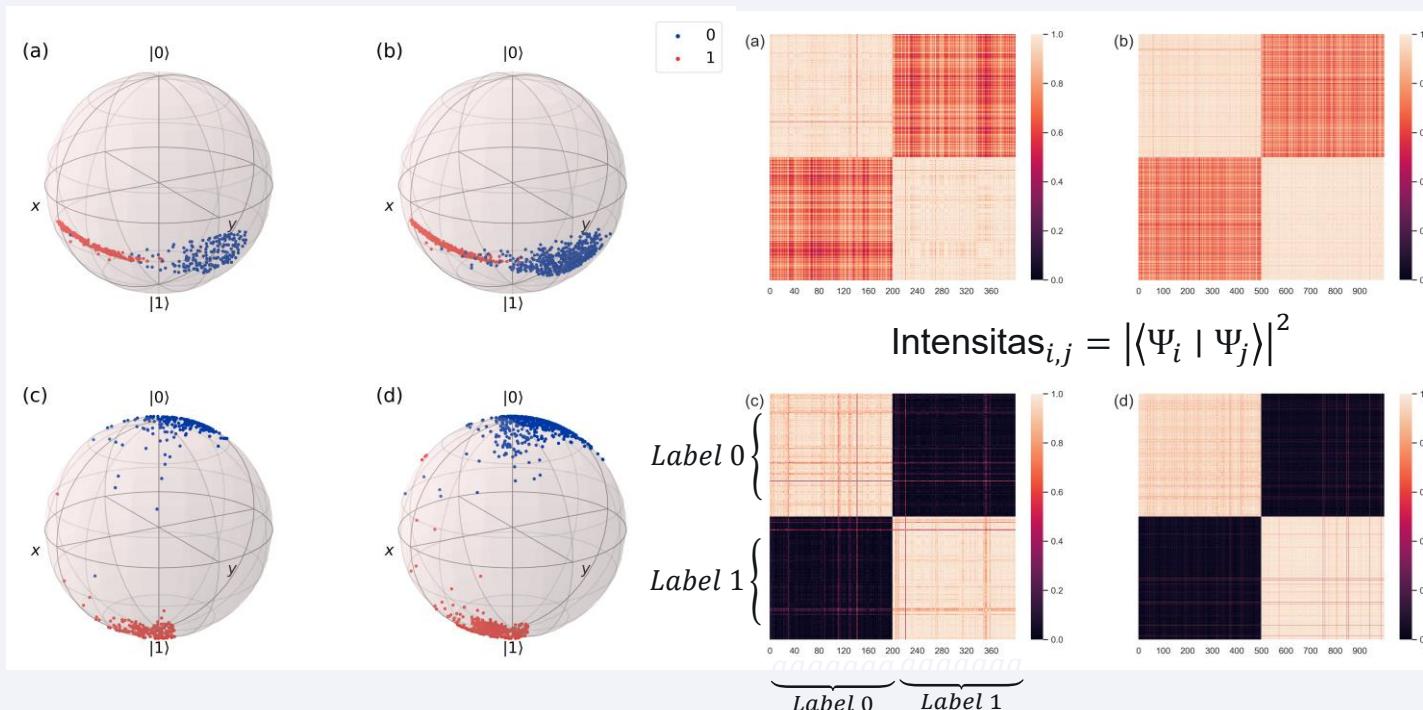
Pengklasifikasi DRC dengan PCA: 2 Kelas

- Qubit digunakan: 1
- Akurasi dari model terbaik yang diperoleh dalam rentang 10 epoch/iterasi
- Penambahan jumlah lapisan berpengaruh signifikan pada akurasi



Pengklasifikasi DRC dengan PCA: 2 Kelas

Representasi keadaan kuantum tiap sampel data pada *Bloch Sphere* &
Representasi *heatmap* dari nilai *overlap/fidelitas* antar tiap 2 keadaan kuantum sampel data

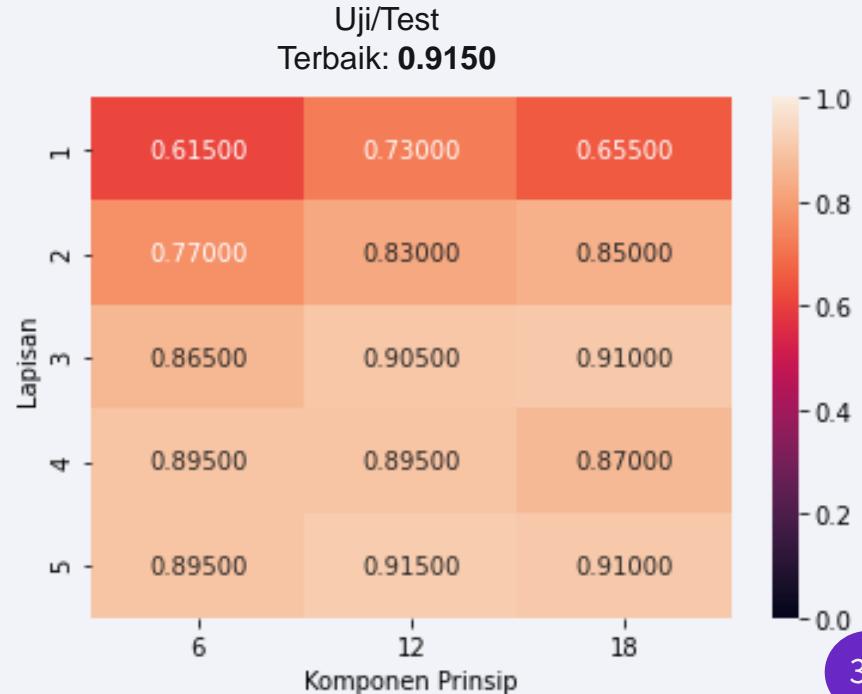
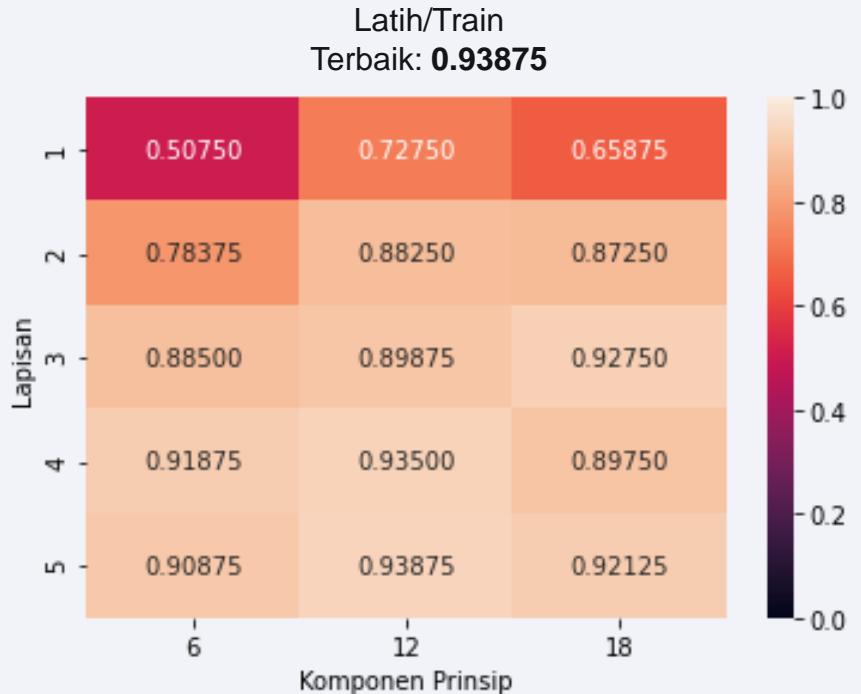


Sampel Data Latih:
(a) Sebelum Training
(c) Setelah Training

Sampel Data Uji:
(b) Sebelum Training
(d) Setelah Training

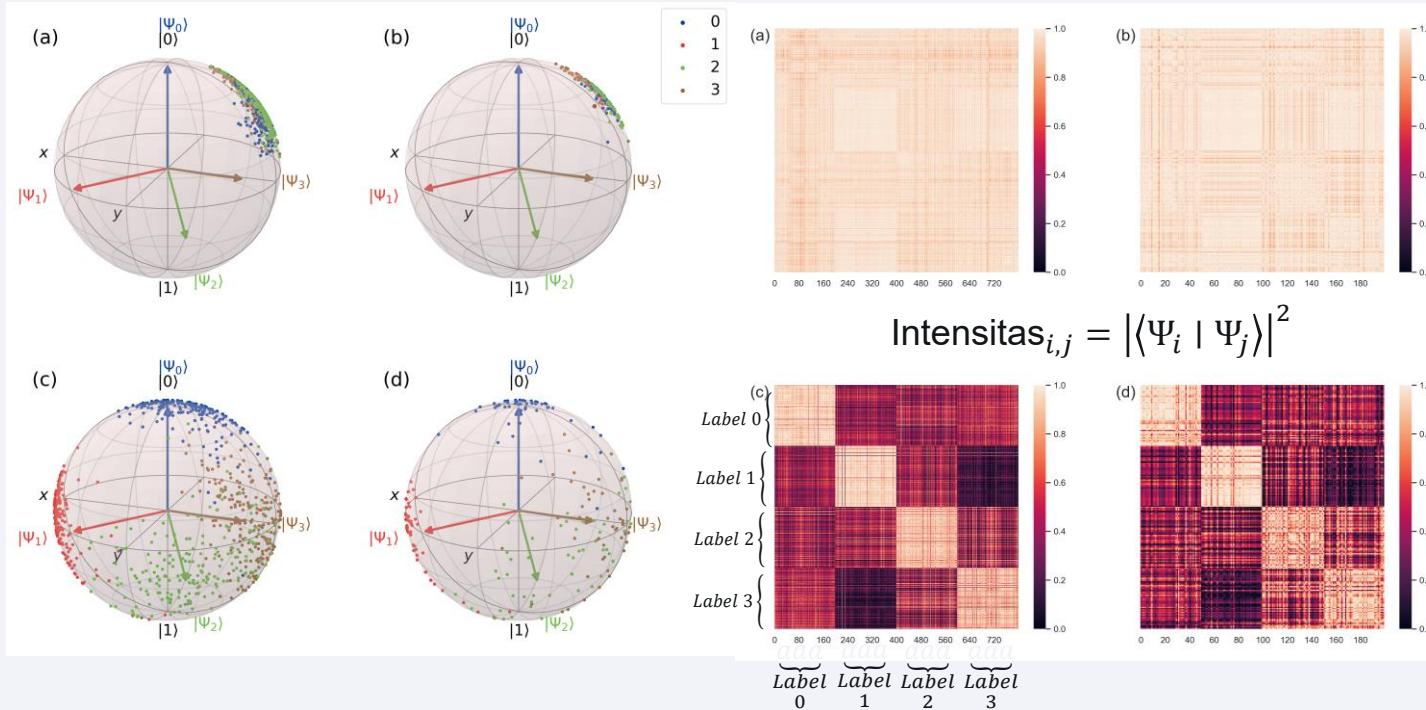
Pengklasifikasi DRC dengan PCA: 4 Kelas

- Qubit digunakan: 1
- Akurasi dari model terbaik yang diperoleh dalam rentang 10 epoch/iterasi
- Penambahan jumlah lapisan berpengaruh signifikan pada akurasi
- Drop akurasi yang relatif cukup besar dibandingkan klasifikasi 2 kelas



Pengklasifikasi DRC dengan PCA: 4 Kelas

Representasi keadaan kuantum tiap sampel data pada *Bloch Sphere* &
Representasi *heatmap* dari nilai *overlap/fidelitas* antar tiap 2 keadaan kuantum sampel data



Sampel Data Latih:
(a) Sebelum Training
(c) Setelah Training

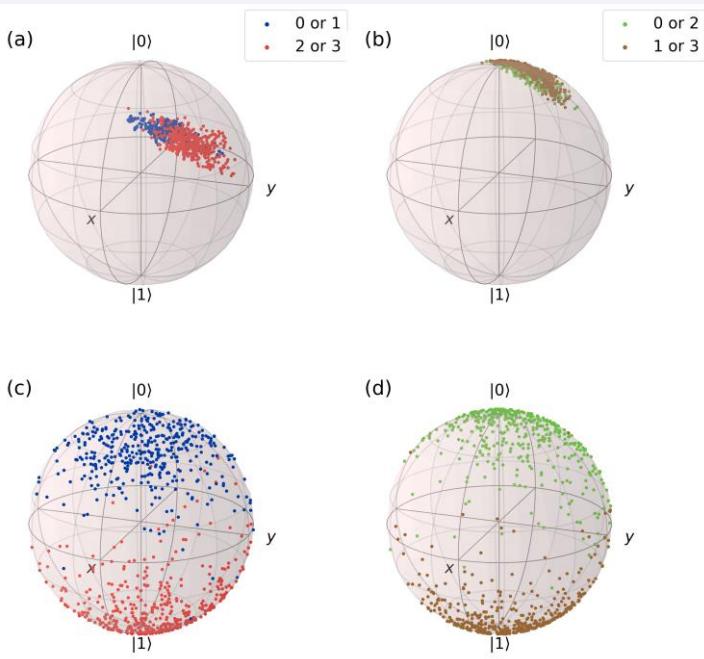
Sampel Data Uji:
(b) Sebelum Training
(d) Setelah Training

Pengklasifikasi DRC-RB dengan PCA: 4 Kelas

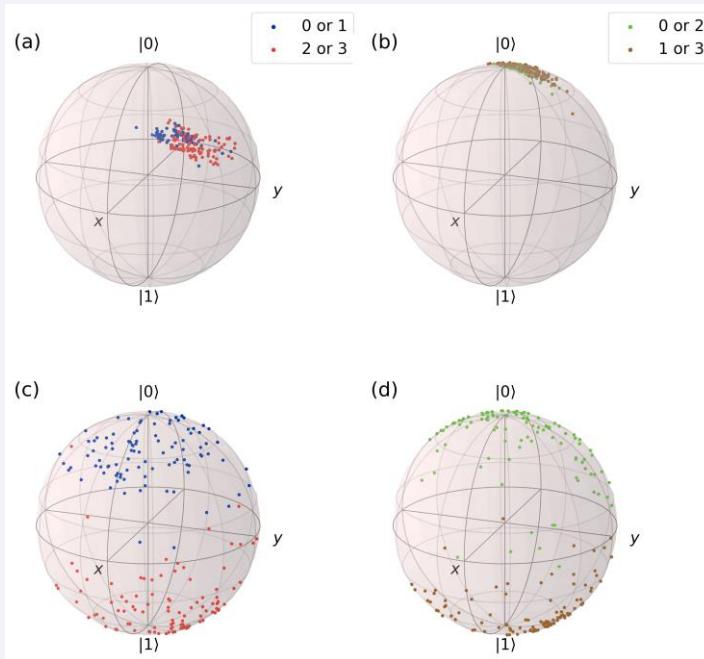
Representasi keadaan kuantum tiap sampel data pada *Bloch Sphere*

Nilai akurasi didapat dari model terbaik dalam rentang 10 epoch/iterasi dengan 4 lapisan dan 18 komponen prinsip

Latih/Train



Uji/Test



- (a) Sebelum Training Qubit 0
- (b) Sebelum Training Qubit 1
- (c) Setelah Training Qubit 0
- (d) Setelah Training Qubit 1

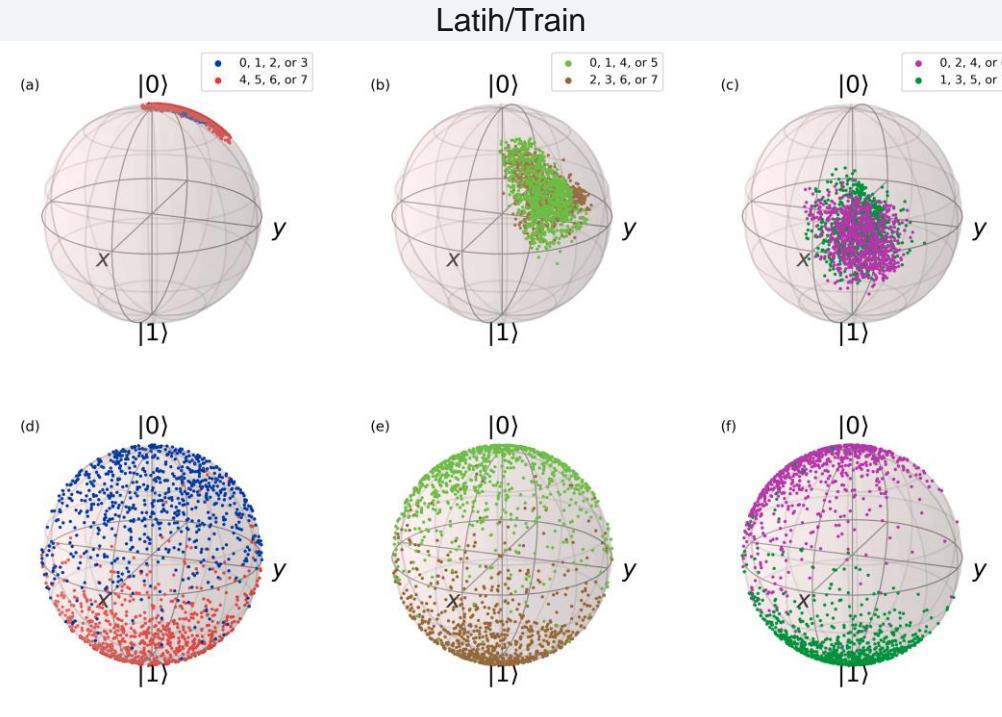
Akurasi Latih Terbaik: 0.95625
(naik sekitar 1.7%)

Akurasi Uji Terbaik: 0.965
(naik 5%)

Pengklasifikasi DRC-RB dengan PCA: 8 Kelas

Representasi keadaan kuantum tiap sampel data pada *Bloch Sphere*

Nilai akurasi didapat dari model terbaik dalam rentang 10 epoch/iterasi dengan 4 lapisan dan 27 komponen prinsip

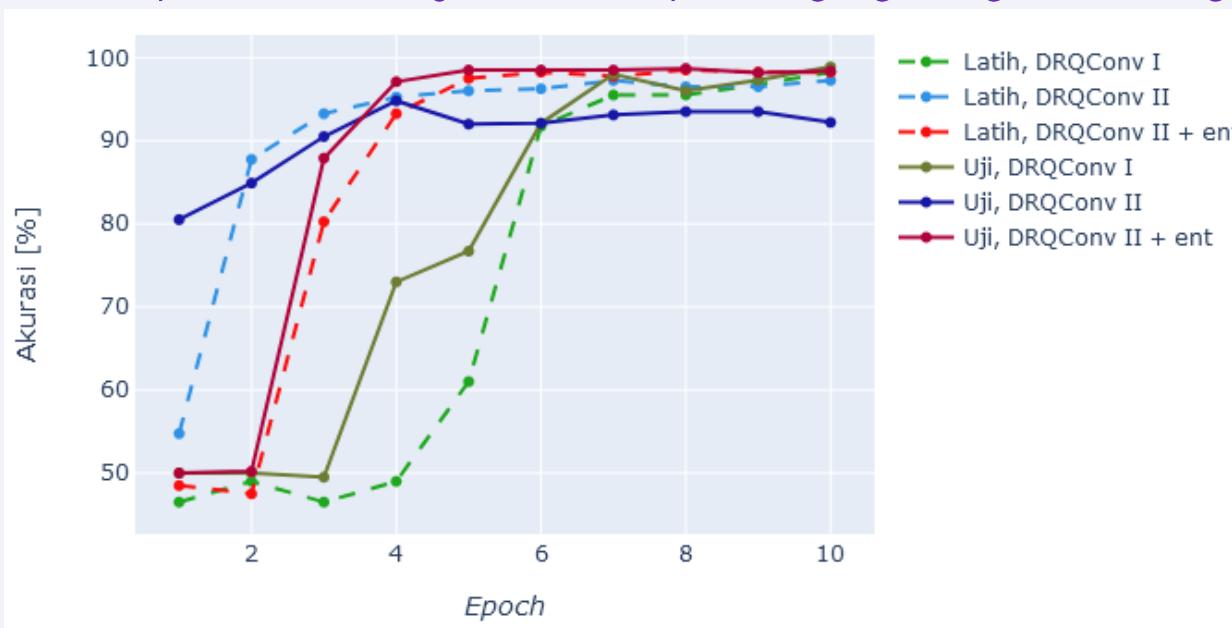


- label 0 → $|0\rangle|0\rangle|0\rangle$
- label 1 → $|0\rangle|0\rangle|1\rangle$
- label 2 → $|0\rangle|1\rangle|0\rangle$
- label 3 → $|0\rangle|1\rangle|1\rangle$
- label 4 → $|1\rangle|0\rangle|0\rangle$
- label 5 → $|1\rangle|0\rangle|1\rangle$
- label 6 → $|1\rangle|1\rangle|0\rangle$
- label 7 → $|1\rangle|1\rangle|1\rangle$

Akurasi Latih Terbaik: 0.8775
 Akurasi Uji Terbaik: 0.8625

Pengklasifikasi DRC-RB dengan Konvolusi Kuantum: 2 Kelas

- DRQConv II menghasilkan nilai akurasi yang lebih rendah dibandingkan sirkuit lain
- DRQConv I (3 qubit) mampu menyamai akurasi DRQConv II + ent (9 qubit) dan melebihi akurasi DRQConv II (9 qubit), meski lebih lama mencapai konvergen
- Akurasi tidak serta merta berbanding lurus dengan jumlah qubit digunakan, arsitektur sirkuit dan bagaimana data disematkan lebih berpengaruh
- Terdapat indikasi *entanglement* antar qubit dengan gerbang CNOT meningkatkan akurasi



Ansatz Sirkut Konvolusi Kuantum	Akurasi	
	Latih Terbaik	Uji Terbaik
DRQConv I	98,250%	98,90%
DRQConv II	97,250%	94,80%
DRQConv II + ent	98,50%	98,70%
JST Konvolusi 2 kelas (64 bit)	99,750%	99,70%

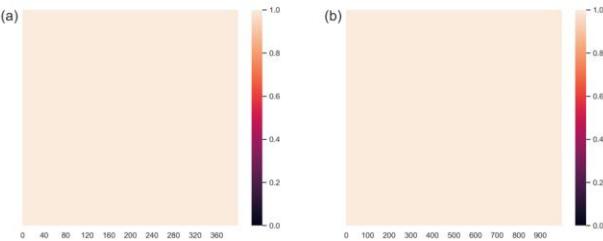
Pengklasifikasi DRC-RB dengan Konvolusi Kuantum: 2 Kelas

- Kemampuan separasi kelas: DRQConv I < DRQConv II < DRQConv II + ent
- Terdapat indikasi penggunaan jumlah qubit lebih banyak dan *entanglement* membuat separasi antar kelas oleh sirkuit lebih baik (presisi)
- Trade-off* antara akurasi dengan presisi

Sampel Data Latih:
 (a) Sebelum Training
 (c) Setelah Training

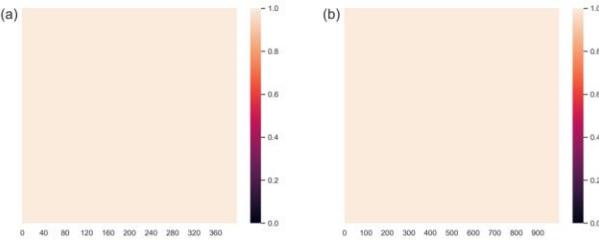
Sampel Data Uji:
 (b) Sebelum Training
 (d) Setelah Training

DRQConv I



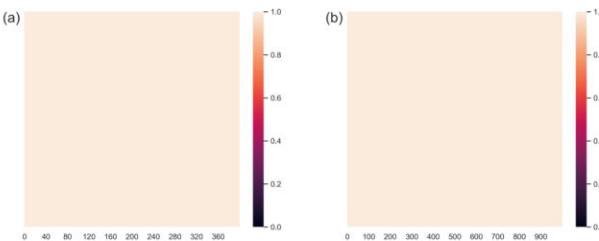
$$\text{Intensitas}_{i,j} = |\langle \Psi_i | \Psi_j \rangle|^2$$

DRQConv II

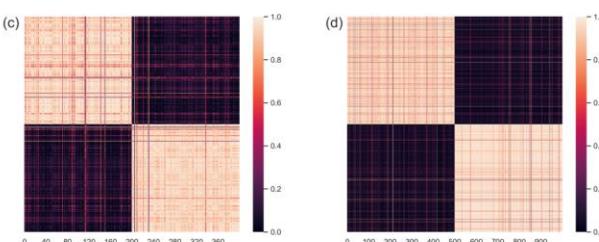
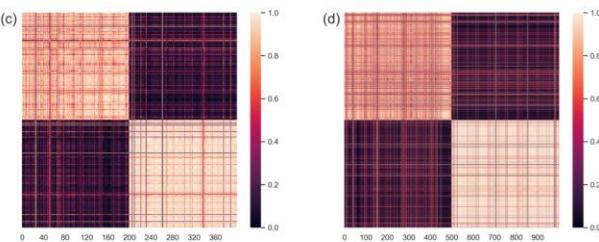
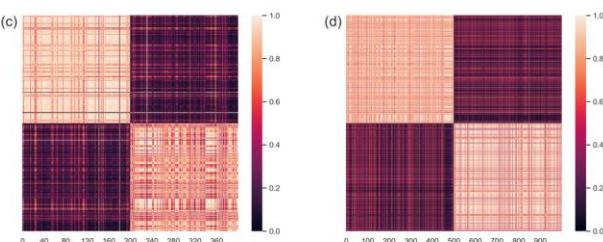


$$\text{Intensitas}_{i,j} = |\langle \Psi_i | \Psi_j \rangle|^2$$

DRQConv II + ent



$$\text{Intensitas}_{i,j} = |\langle \Psi_i | \Psi_j \rangle|^2$$



Pengklasifikasi DRC-RB dengan Konvolusi Kuantum: 4 Kelas

- Konsisten dengan kasus 2 kelas, DRQConv II menghasilkan nilai akurasi yang lebih rendah dibandingkan sirkuit lain
- Akurasi tidak serta merta berbanding lurus dengan jumlah qubit digunakan, arsitektur sirkuit dan bagaimana data disematkan lebih berpengaruh
- Terdapat indikasi *entanglement* antar qubit dengan gerbang CNOT meningkatkan akurasi
- Pada kasus 4 kelas, pengklasifikasi dengan komputasi kuantum lebih baik sekitar 1% akurasinya dibandingkan JST Konvolusi (klasik)

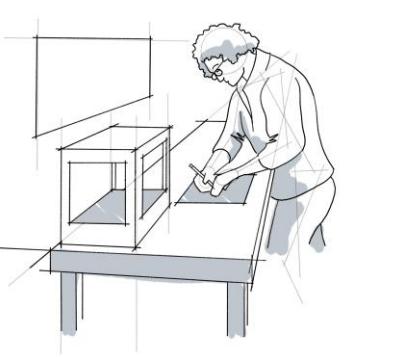
Ansatz Sirkut Konvolusi Kuantum	Akurasi Latih	Akurasi Uji
DRQConv I	89,0%	89,50%
DRQConv II	85,1250%	85,0%
DRQConv II + ent	90,0%	86,50%
JST Konvolusi 4 kelas (64 bit)	87,8750%	88,50%

label 0 = $|0\rangle|1\rangle|1\rangle|1\rangle$

label 1 = $|1\rangle|0\rangle|1\rangle|1\rangle$

label 2 = $|1\rangle|1\rangle|0\rangle|1\rangle$

label 3 = $|1\rangle|1\rangle|1\rangle|0\rangle$



Kesimpulan dan Saran

- Kesimpulan
- Saran

Kesimpulan

Akurasi lebih baik dari penelitian sebelumnya (90%) dengan lebih efisien qubit dan dapat diekspansi ke kasus banyak kelas

Klasifikasi 2 Kelas
Akurasi uji pengklasifikasi DRC (1 qubit) dengan reduksi PCA: 99,7%

Ekspansi ke banyak kelas dengan DRC-RB (2 & 3 qubit) dan reduksi PCA

- 4 kelas: akurasi uji 96,5%
- 8 kelas: akurasi uji 86,25%

Telah diajukan metode DRQConv: reduksi konvolusi dengan sirkuit kuantum

Klasifikasi 2 Kelas
Akurasi uji pengklasifikasi DRC-RB (1 qubit) dengan reduksi DRQConv I (3 qubit): 98,9%

Klasifikasi 4 Kelas
Akurasi uji pengklasifikasi DRC-RB (4 qubit) dengan reduksi DRQConv I (3 qubit): 89,5%



Saran

Saran #1

Melakukan pengujian dengan himpunan data citra lain, misalnya Fashion MNIST dan SIGN MNIST, untuk melihat seberapa *robust* algoritma terhadap citra yang berbeda.

Saran #2

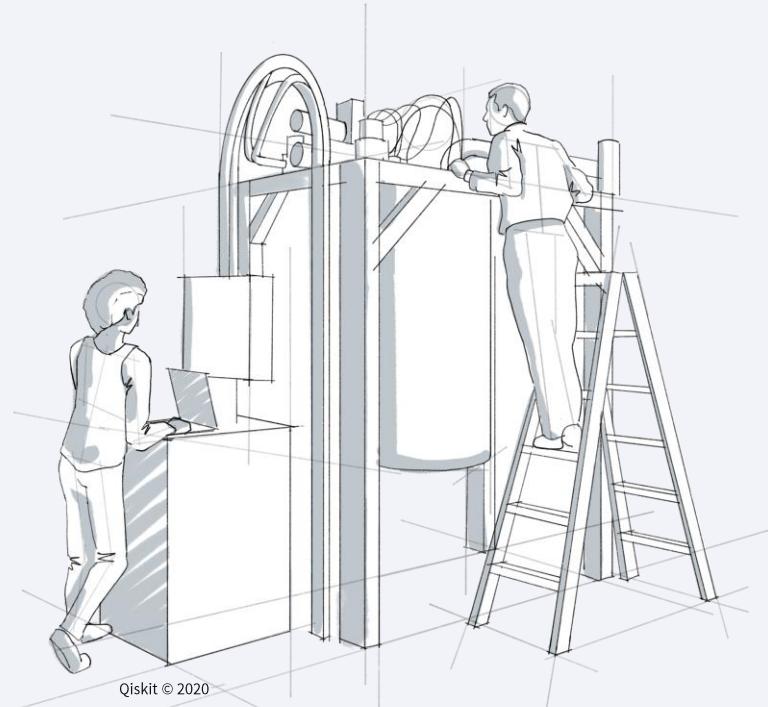
Melakukan pengujian yang berfokus pada variasi jumlah qubit dan jumlah gerbang *peng-entangle* (seperti gerbang CNOT) dengan arsitektur sirkuit yang sama untuk mencari tau secara detil bagaimana pengaruhnya pada performa akurasi.



Terima Kasih!
Ada Pertanyaan?

Referensi

- [1] Grumblng E, Horowitz M. Quantum Computing: Progress and Prospects. vol. 9781461418. Washington, D.C.: National Academies Press; 2019. <https://doi.org/10.17226/25196>.
- [2] Biamonte J, Wittek P, Pancotti N, Rebentrost P, Wiebe N, Lloyd S. Quantum machine learning. *Nature* 2017;549:195–202. <https://doi.org/10.1038/nature23474>.
- [3] Preskill J. Quantum Computing in the NISQ era and beyond. *Quantum* 2018;2. <https://doi.org/10.22331/q-2018-08-06-79>.
- [4] Cerezo M, Arrasmith A, Babbush R, Benjamin SC, Endo S, Fujii K, et al. Variational Quantum Algorithms 2020.
- [5] LeCun Y, Cortes C. MNIST handwritten digit database 2010.
- [6a] Farhi E, Neven H. Classification with Quantum Neural Networks on Near Term Processors 2018:1–21.
- [6b] MNIST classification | TensorFlow Quantum n.d. <https://www.tensorflow.org/quantum/tutorials/mnist> (diakses 6 Februari 2021).
- [7] Skolik A, McClean JR, Mohseni M, van der Smagt P, Leib M. Layerwise learning for quantum neural networks. *Quantum Mach Intell* 2021;3:5. <https://doi.org/10.1007/s42484-020-00036-4>.
- [8] Mardirosian S. Quantum-enhanced Supervised Learning with Variational Quantum Circuits. Leiden University, 2019.
- [9] Pérez-Salinas A, Cervera-Lierta A, Gil-Fuster E, Latorre JI. Data reuploading for a universal quantum classifier. *Quantum* 2020;4:226. <https://doi.org/10.22331/q-2020-02-06-226>.
- [10] Bloch sphere Wikipedia n.d. https://en.wikipedia.org/wiki/Bloch_sphere#cite_note-1 (diakses 31 Januari 2021).
- [11] Quantum Logic Gates - Quantum logic gate - Wikipedia n.d. https://en.wikipedia.org/wiki/Quantum_logic_gate#/media/File:Quantum_L_ogic_Gates.png (diakses 30 Januari 2021).
- [12] Jolliffe IT, Cadima J. Principal component analysis: a review and recent developments. *Philos Trans R Soc A Math Phys Eng Sci* 2016;374:20150202. <https://doi.org/10.1098/rsta.2015.0202>.
- [13] Sumit S. A Comprehensive Guide to Convolutional Neural Networks — the ELI5 way n.d. <https://towardsdatascience.com/a-comprehensive-guide-to-convolutional-neural-networks-the-eli5-way-3bd2b1164a53> (diakses 16 Maret 2020).



Qiskit © 2020

LAMPIRAN

Algoritma PCA

Algoritma PCA yang diterapkan sebagai berikut:

1. Misal himpunan data D dengan M sampel dan N fitur

$$D = \begin{bmatrix} x_1^1 & \cdots & x_1^N \\ \vdots & \ddots & \vdots \\ x_M^1 & \cdots & x_M^N \end{bmatrix}$$

Lakukan standardisasi data

$$\mu_j = \frac{\sum_{i=1}^M x_i^j}{M}, \quad \sigma_j = \sqrt{\frac{\sum_{i=1}^M (x_i^j - \mu_j)^2}{M}}$$

$$x_i^j = \frac{x_i^j - \mu_j}{\sigma_j + \epsilon}$$

Algoritma PCA

2. Hitung matriks kovarians C

$$C = \begin{bmatrix} C_{11} & \cdots & C_{1N} \\ \vdots & \ddots & \vdots \\ C_{N1} & \cdots & C_{NN} \end{bmatrix}, \quad C_{pq} = \frac{\sum_{i=1}^M (x_i^p - \mu_p)(x_i^q - \mu_q)}{M}$$

3. Hitung nilai eigen dan vektor eigen dari matriks kovarians C

$$\begin{aligned}\lambda &= \{\lambda_1, \lambda_2, \dots, \lambda_N\} \\ v &= \{v_1, v_2, \dots, v_N\}\end{aligned}$$

4. Urutkan vektor eigen v berdasarkan urutan nilai eigen λ dari yang terbesar

$$\begin{aligned}\lambda_{urut} &= \underbrace{\{\lambda_a, \lambda_b, \lambda_c, \dots\}}_N \\ v_{urut} &= \underbrace{\{v_a, v_b, v_c, \dots\}}_N\end{aligned}$$

Algoritma PCA

5. Misal ingin diambil komponen prinsip sebanyak $k \leq N$, maka matriks proyeksinya

$$P = \underbrace{\{v_a, v_b, v_c, \dots\}}_k$$

6. Transformasikan himpunan data dengan matriks proyeksi P

$$D' = D \cdot P$$

Adaptive Moment Estimation (Adam)

Inisialisasi awal:

$$V_{\theta_G} = 0, \quad S_{\theta_G} = 0, \quad t = 0$$

Tiap langkah optimisasi:

$$\begin{aligned} t &= t + 1 \\ V_{\theta_G} &= \frac{\beta_1 V_{\theta_G} + (1 - \beta_1) \frac{\partial}{\partial \theta_G} J(\vec{\theta})}{1 - (\beta_1)^t} \\ S_{\theta_G} &= \frac{\beta_2 S_{\theta_G} + (1 - \beta_2) \left(\frac{\partial}{\partial \theta_G} J(\vec{\theta}) \right)^2}{1 - (\beta_2)^t} \\ \theta_G &= \theta_G - \eta \frac{V_{\theta_G}}{\sqrt{S_{\theta_G}} + \epsilon} \end{aligned}$$

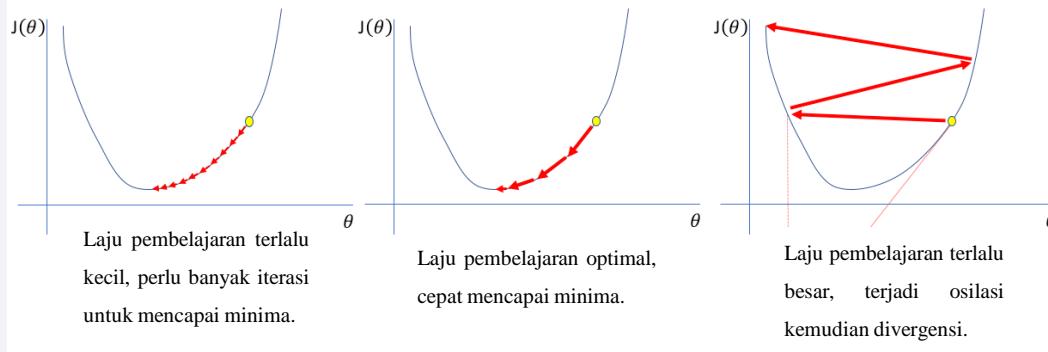
$$\beta_1 = 0.9, \quad \beta_2 = 0.999, \quad \text{dan } \epsilon = 10^{-7}$$

Laju Pembelajaran Meluruh

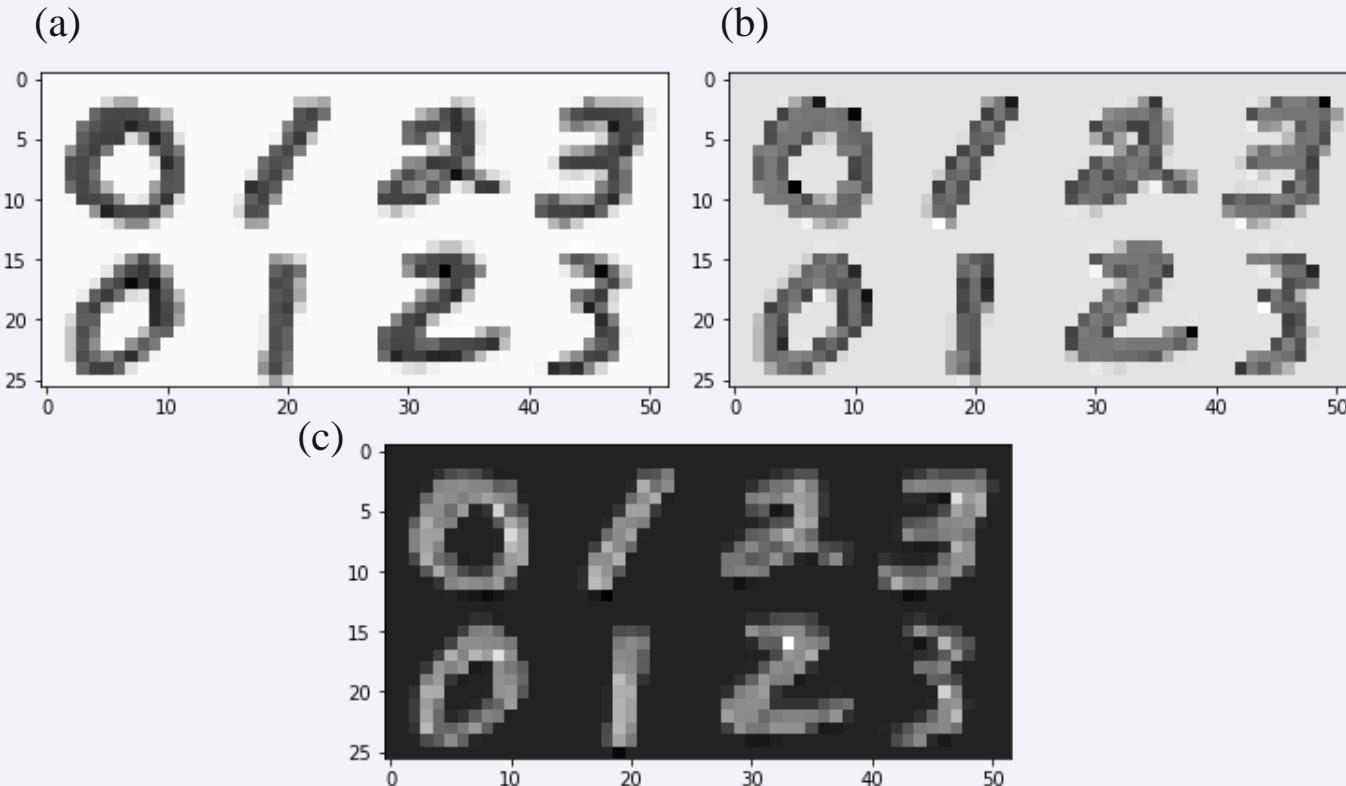
Inisialisasi nilai laju pembelajaran awal η_0 , konstanta laju peluruhan τ , dan konstanta langkah peluruhan Δ

Tiap langkah optimisasi:

$$t = t + 1$$
$$\eta = \eta_0 \times \tau^{\frac{t}{\Delta}}$$

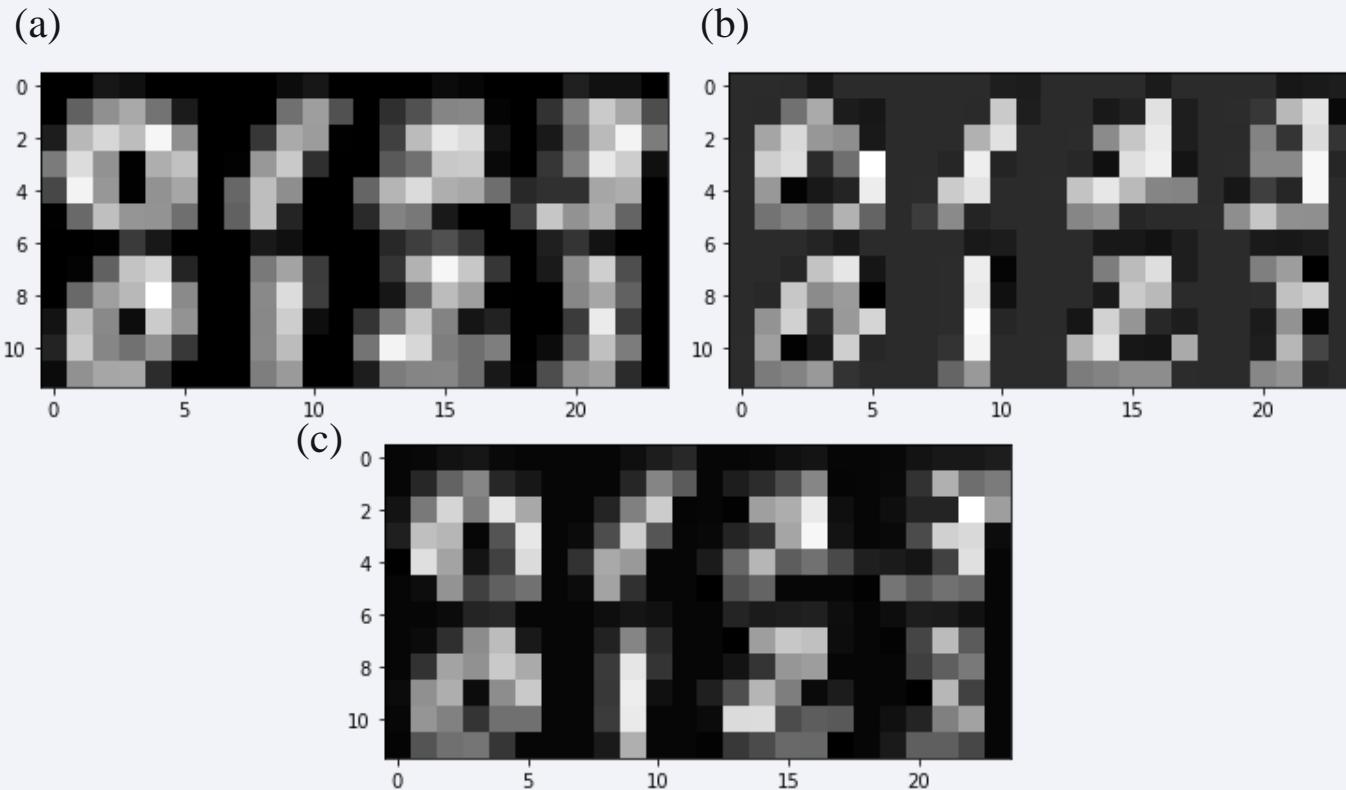


Citra Keluaran Konvolusi Kuantum



Citra keluaran konvolusi kuantum pertama dari sirkuit (a) DRQConv I, (b) DRQConv II, dan (c) DRQConv II + ent.

Citra Keluaran Konvolusi Kuantum



Citra keluaran konvolusi kuantum kedua dari sirkuit (a) DRQConv I, (b) DRQConv II, dan (c) DRQConv II + ent.

Pengklasifikasi DRC dengan Reduksi PCA

Spesifikasi

Jumlah sampel data latih	200 sampel/kelas
Jumlah sampel data uji	500 sampel/kelas untuk 2 kelas, 50 sampel/kelas untuk 4 kelas
Epoch	10 iterasi
Ukuran batch	32 sampel
Algoritma Optimisasi	Adam
Laju pembelajaran	0,1 (konstan)
Jumlah komponen prinsip PCA (p)	Divariasikan
Jumlah qubit untuk DRC (Q)	1
Jumlah lapisan DRC (L)	Divariasikan
Total parameter yang perlu dioptimisasi	$2 \times L \times p + C$
Fungsi biaya	MSE

Pengklasifikasi DRC Representasi Biner dengan Reduksi PCA Spesifikasi

Jumlah sampel data latih	200 sampel/kelas
Jumlah sampel data uji	50 sampel/kelas
Epoch	10 iterasi
Ukuran batch	32 sampel untuk 4 kelas, 64 sampel untuk 8 kelas
Algoritma Optimisasi	Adam
Laju pembelajaran	0,1 (konstan) untuk 4 kelas, laju pembelajaran meluruh untuk 8 kelas dengan $\eta_0 = 0,1$, $\tau = 0,95$, dan $\Delta = 50$
Jumlah komponen prinsip PCA (p)	Divariasikan
Jumlah qubit untuk DRC (Q)	$\log_2 C$
Jumlah lapisan DRC (L)	Divariasikan
Total parameter yang perlu dioptimisasi	$(2 \times L \times p + 2) \times \log_2 C$
Fungsi biaya	MSE

Pengklasifikasi DRC Representasi Biner dengan Reduksi Konvolusi Kuantum (DRQConv)

Spesifikasi 2 Kelas

Jumlah sampel data latih	200 sampel/kelas
Jumlah sampel data uji	500 sampel/kelas
Epoch	10 iterasi
Ukuran batch	32 sampel
Algoritma Optimisasi	Adam
Laju pembelajaran	0,1 (konstan)
Jumlah Proses Konvolusi	2 kali konvolusi. Citra awal 27×27 menjadi 13×13 setelah konvolusi pertama dan menjadi 6×6 setelah konvolusi kedua
Jumlah qubit untuk DRQConv (Q)	DRQConv I: 3 DRQConv II: 9 DRQConv II + ent: 9
Jumlah lapisan DRQConv (L) pada tiap proses konvolusi	1
Jumlah operasi pooling	1 kali max pooling setelah konvolusi kedua dengan ukuran filter 3×3 dan stride 2. Ukuran citra menjadi 3×3 setelah operasi pooling
Jumlah qubit untuk DRC (Q)	1
Jumlah lapisan DRC (L)	1
Total parameter yang perlu dioptimisasi	Parameter DRQConv: $18 + 18 = 36$ Parameter DRC: $18 + 2 = 20$ Total parameter: 56
Fungsi biaya	MSE

Pengklasifikasi JST Konvolusi

Spesifikasi 2 Kelas

Jumlah sampel data latih	200 sampel/kelas
Jumlah sampel data uji	500 sampel/kelas
Epoch	10 iterasi
Ukuran batch	32 sampel
Algoritma Optimisasi	Adam
Laju pembelajaran	0,1 (konstan)
Jumlah Proses Konvolusi	2 kali konvolusi. Citra awal 27×27 menjadi 13×13 setelah konvolusi pertama dan menjadi 6×6 setelah konvolusi kedua
Spesifikasi filter	Ukuran filter 3×3 dengan strides 2. Digunakan 2 filter pada konvolusi pertama dan 1 filter pada konvolusi kedua. Fungsi aktivasi yang digunakan adalah ReLU
Jumlah operasi pooling	1 kali max pooling setelah konvolusi kedua dengan ukuran filter 2×2 dan stride 2. Ukuran citra menjadi 3×3 setelah operasi pooling
Jumlah lapisan dan simpul JST	Keluaran max pooling kemudian diratakan dan diumpulkan ke lapisan keluaran JST dengan jumlah simpul 2 dan fungsi aktivasi softmax
Total parameter yang perlu dioptimisasi	Parameter Konvolusi: $18 + 18 = 36$ Parameter JST: 20 Total parameter: 56
Fungsi biaya	Categorical crossentropy

Pengklasifikasi DRC Representasi Biner dengan Reduksi Konvolusi Kuantum (DRQConv)

Spesifikasi 4 Kelas

label 0 = 0111

label 1 = 1011

label 2 = 1101

label 3 = 1110

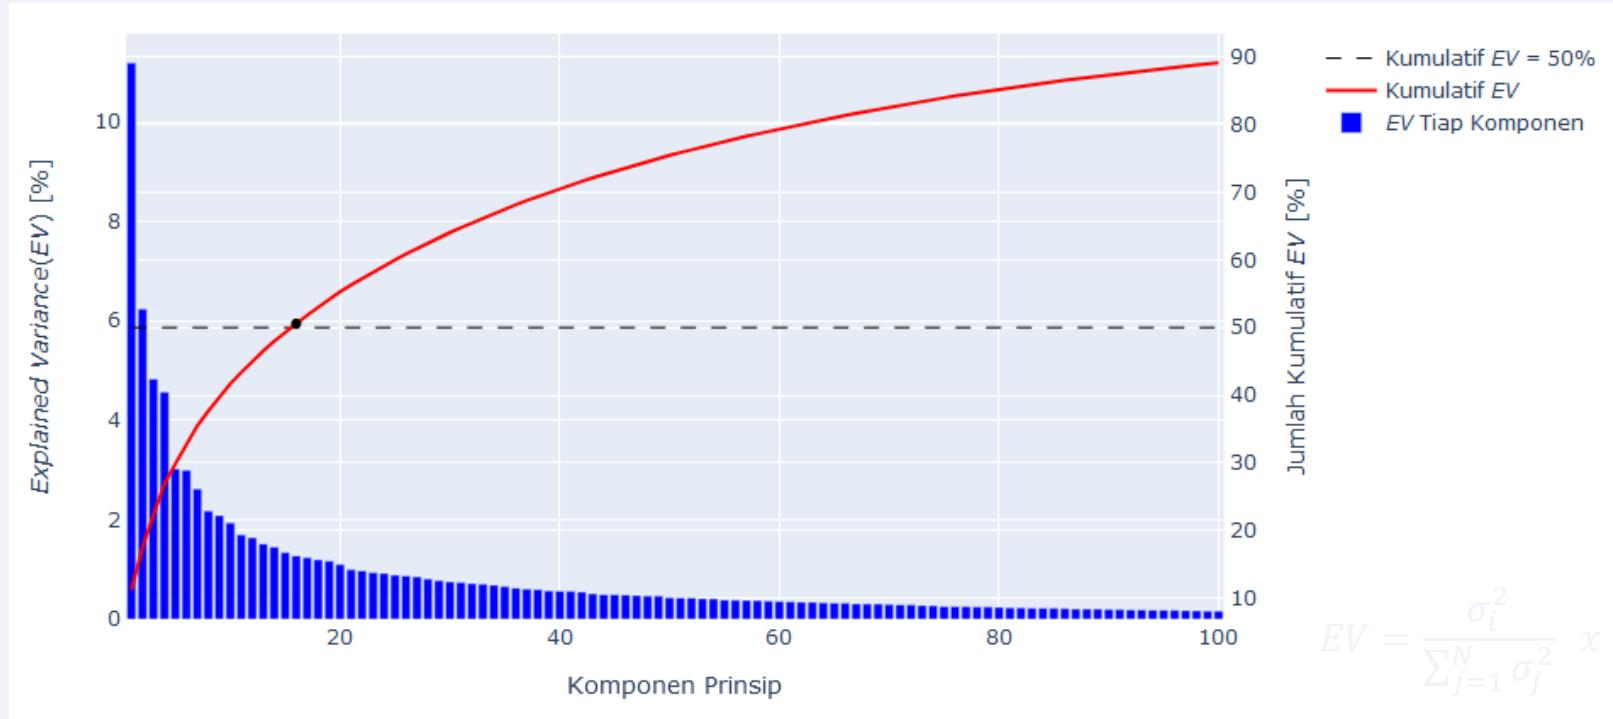
Jumlah sampel data latih	200 sampel/kelas
Jumlah sampel data uji	50 sampel/kelas
Epoch	10 iterasi x 2 proses latih
Ukuran batch	32 sampel
Algoritma Optimisasi	Adam
Laju pembelajaran	0,1 (konstan) pada proses latih pertama, laju pembelajaran meluruh pada proses latih kedua dengan $\eta_0 = 0,1$, $\tau = 0,95$, dan $\Delta = 25$
Jumlah Proses Konvolusi	2 kali konvolusi. Citra awal 27 x 27 menjadi 13 x 13 setelah konvolusi pertama dan menjadi 6 x 6 setelah konvolusi kedua
Jumlah qubit untuk DRQConv (Q)	DRQConv I: 3 DRQConv II: 9 DRQConv II + ent: 9
Jumlah lapisan DRQConv (L) pada tiap proses konvolusi	2
Jumlah operasi pooling	1 kali max pooling setelah konvolusi kedua dengan ukuran filter 3 x 3 dan stride 2. Ukuran citra menjadi 3 x 3 setelah operasi pooling
Jumlah qubit untuk DRC (Q)	4
Jumlah lapisan DRC (L)	2
Total parameter yang perlu dioptimisasi	Parameter DRQConv: $2 \times (18 + 18) = 72$ Parameter DRC: $4 \times (2 \times 18 + 2) = 152$ Total parameter: 224
Fungsi biaya	MSE

Pengklasifikasi JST Konvolusi

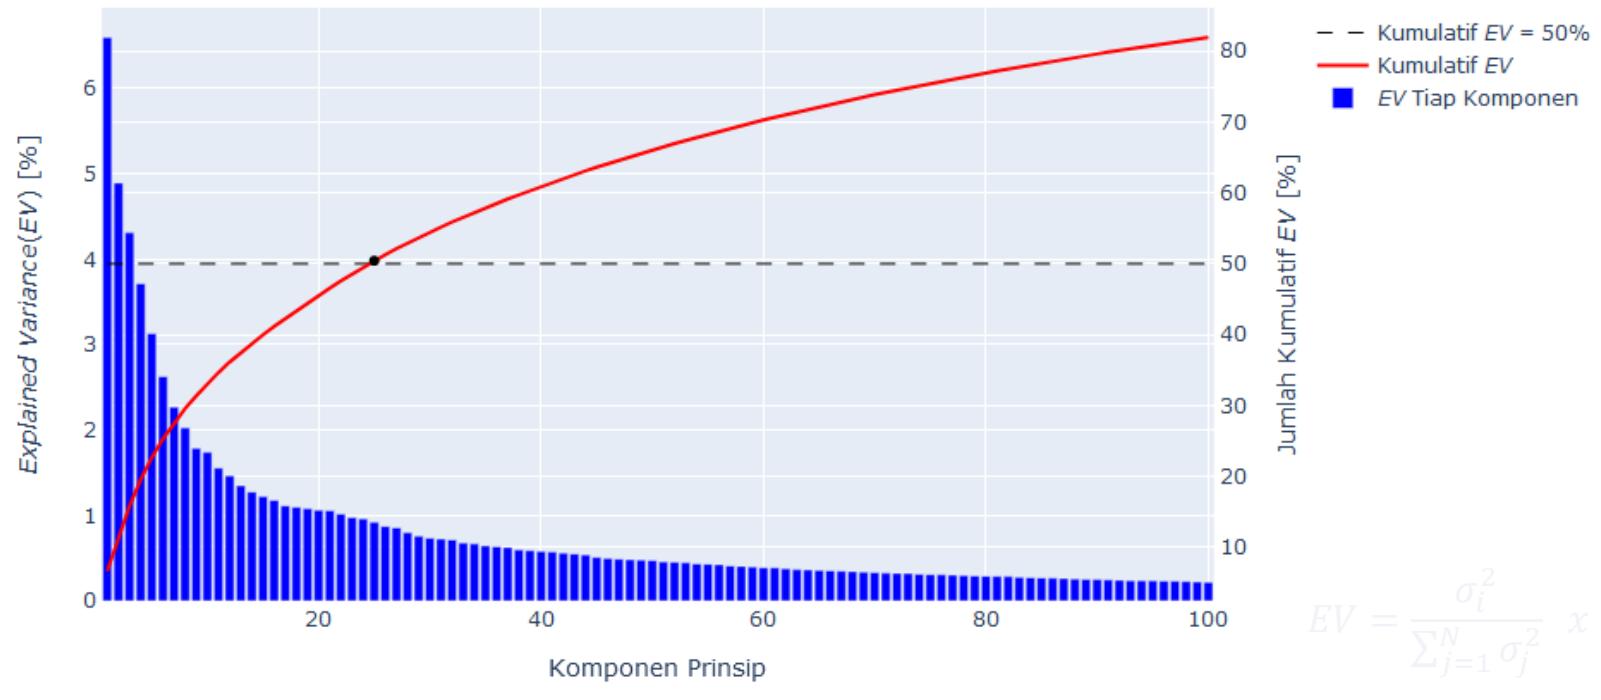
Spesifikasi 4 Kelas

Jumlah sampel data latih	200 sampel/kelas
Jumlah sampel data uji	50 sampel/kelas
Epoch	10 iterasi x 2 proses latih
Ukuran batch	32 sampel
Algoritma Optimisasi	Adam
Laju pembelajaran	0,1 (konstan) pada proses latih pertama, laju pembelajaran meluruh pada proses latih kedua dengan $\eta_0 = 0,1$, $\tau = 0,95$, dan $\Delta = 25$
Jumlah Proses Konvolusi	2 kali konvolusi. Citra awal 27×27 menjadi 13×13 setelah konvolusi pertama dan menjadi 6×6 setelah konvolusi kedua
Spesifikasi filter	Ukuran filter 3×3 dengan strides 2. Digunakan 4 filter pada konvolusi pertama dan 1 filter pada konvolusi kedua. Fungsi aktivasi yang digunakan adalah ReLU
Jumlah operasi pooling	1 kali max pooling setelah konvolusi kedua dengan ukuran filter 2×2 dan stride 2. Ukuran citra menjadi 3×3 setelah operasi pooling
Jumlah lapisan dan simpul JST	Keluaran max pooling kemudian diratakan dan diumpulkan ke lapisan tersembunyi dengan jumlah simpul 11 (fungsi aktivasi ReLU) dan lapisan keluaran dengan jumlah simpul 4 (fungsi aktivasi softmax)
Total parameter yang perlu dioptimisasi	Parameter Konvolusi: $36 + 36 = 72$ Parameter JST: $110 + 48 = 158$ Total parameter: 230
Fungsi biaya	Categorical crossentropy

Explained Variance PCA untuk 4 Kelas (Angka 0, 1, 2, 3)

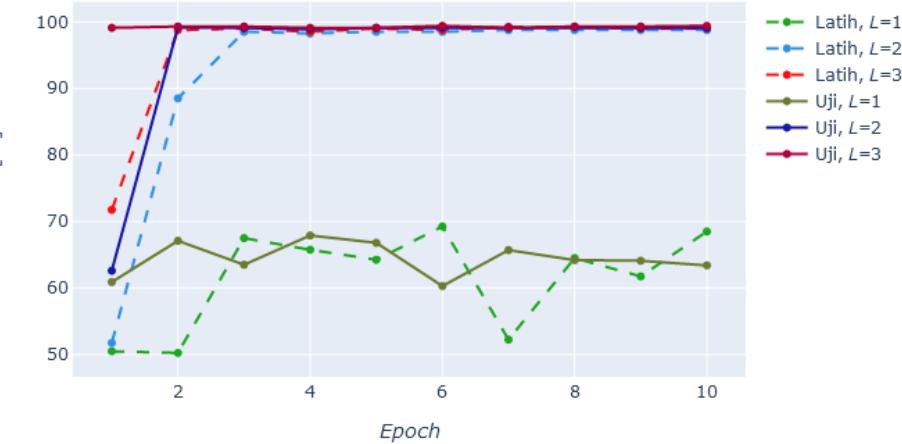


Explained Variance PCA untuk 8 Kelas (Angka 0 - 7)

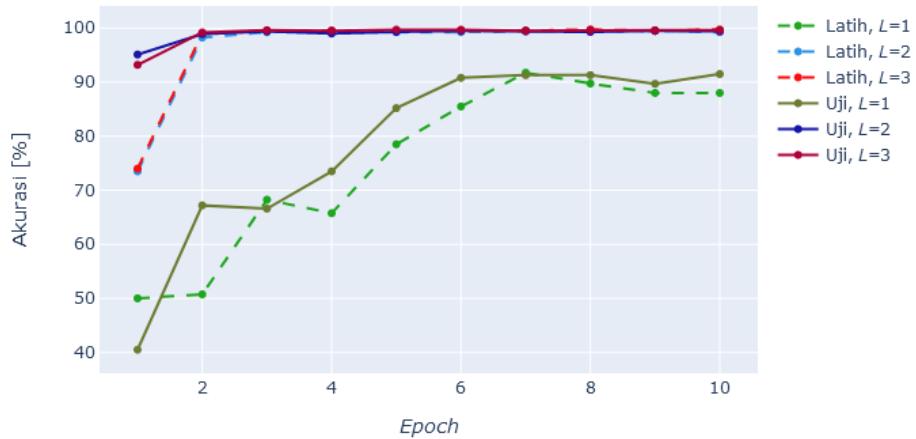


Pengklasifikasi DRC dengan Reduksi PCA 2 Kelas

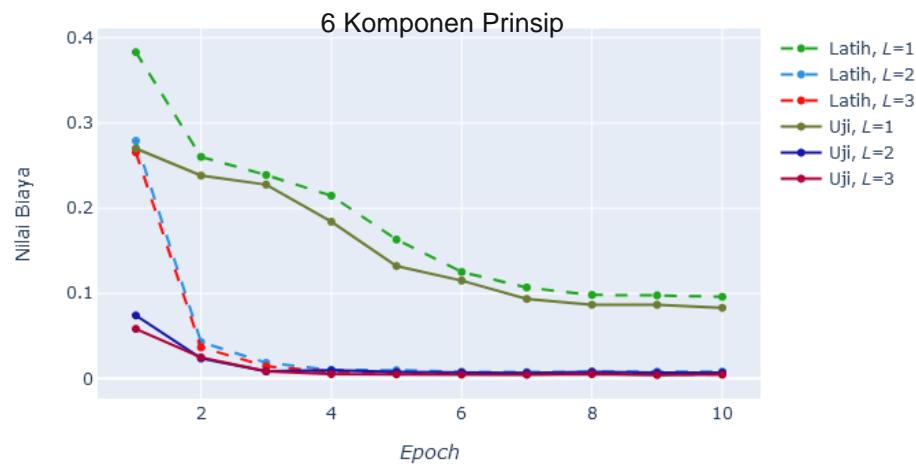
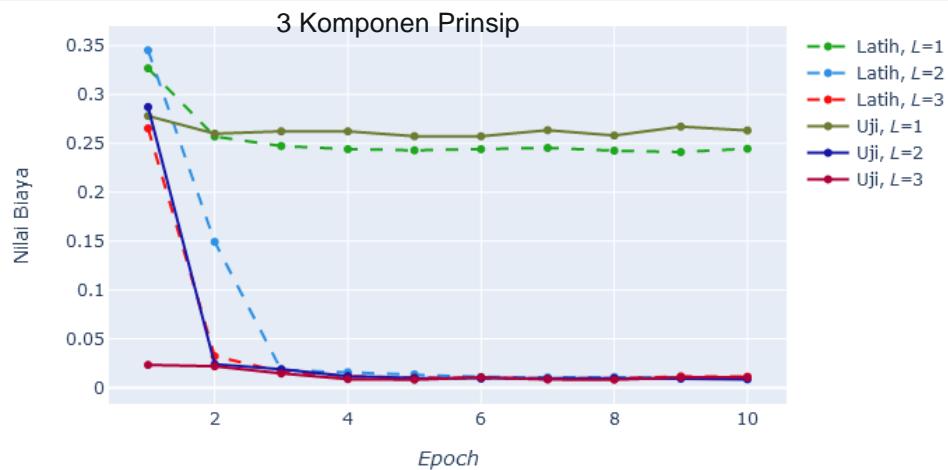
3 Komponen Prinsip



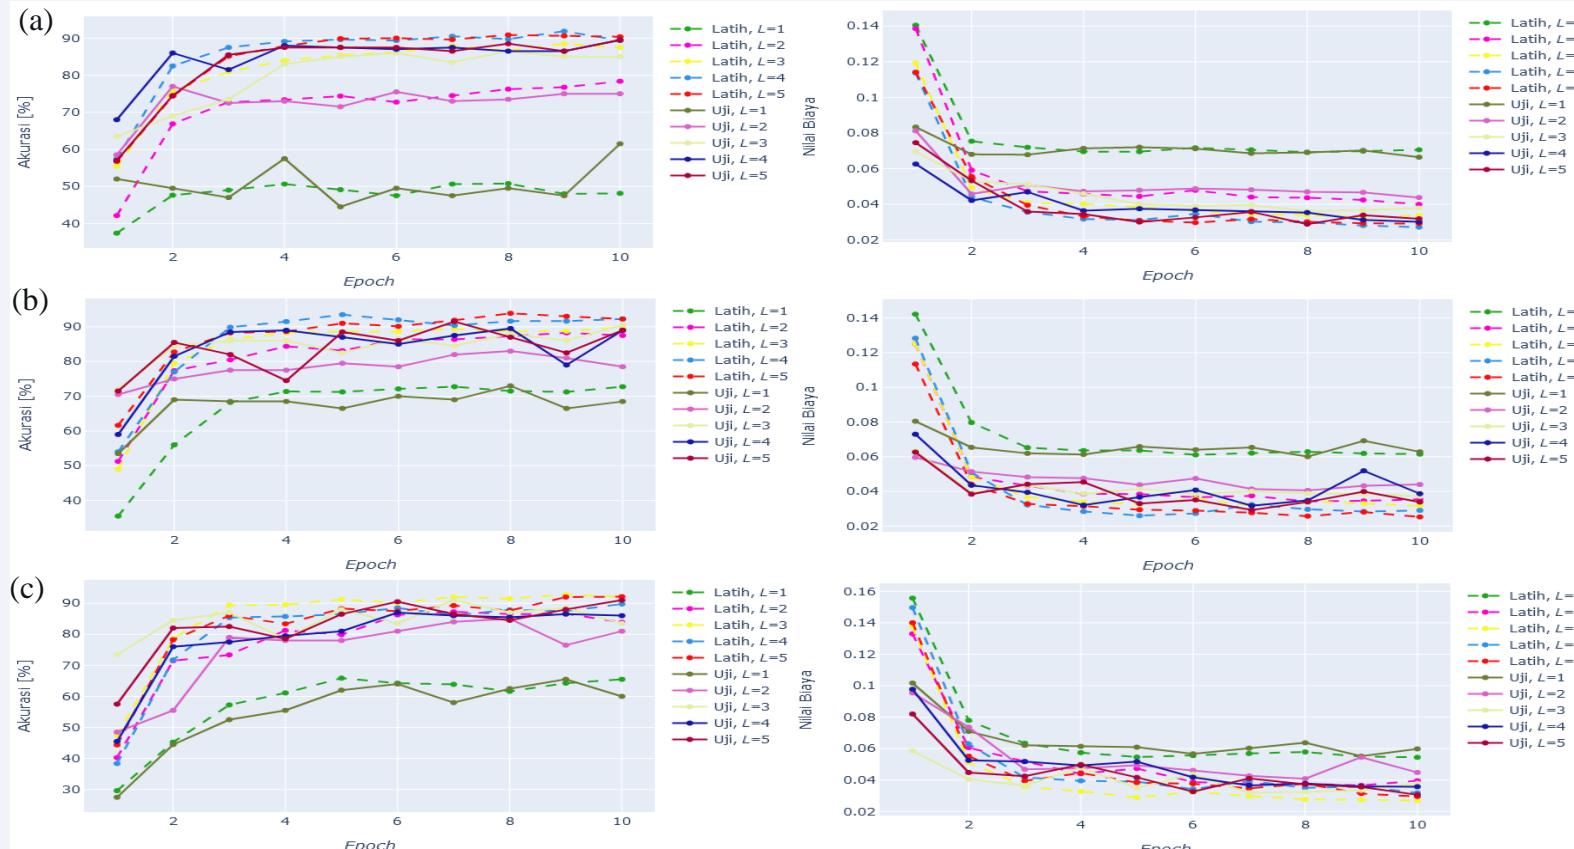
6 Komponen Prinsip



Pengklasifikasi DRC dengan Reduksi PCA 2 Kelas

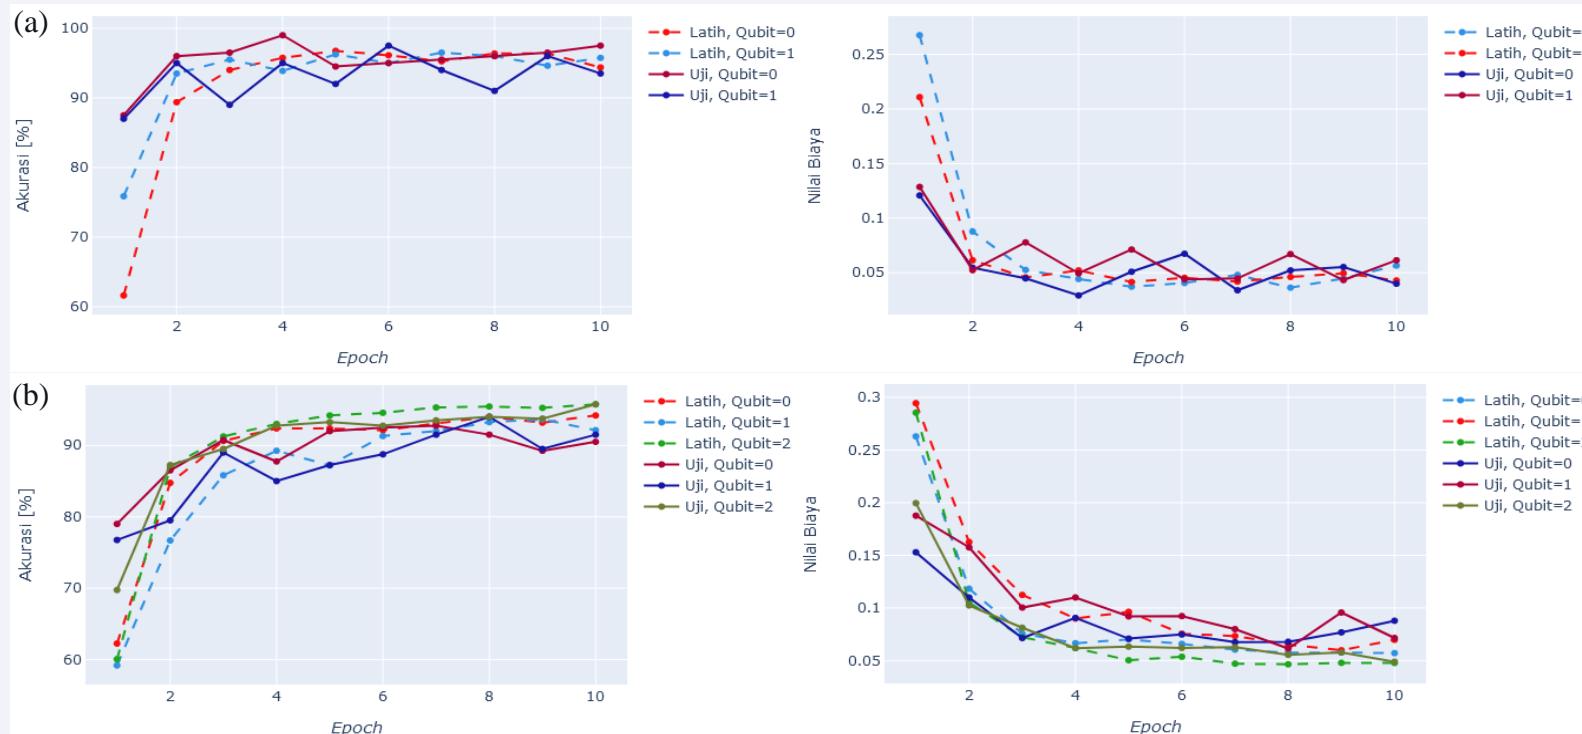


Pengklasifikasi DRC dengan Reduksi PCA: 4 Kelas



Grafik nilai akurasi dan nilai biaya selama proses latih pada kombinasi reduksi PCA (a) 6 komponen prinsip, (b) 12 komponen prinsip, dan (c) 18 komponen prinsip dengan pengklasifikasi DRC untuk klasifikasi 4 kelas.

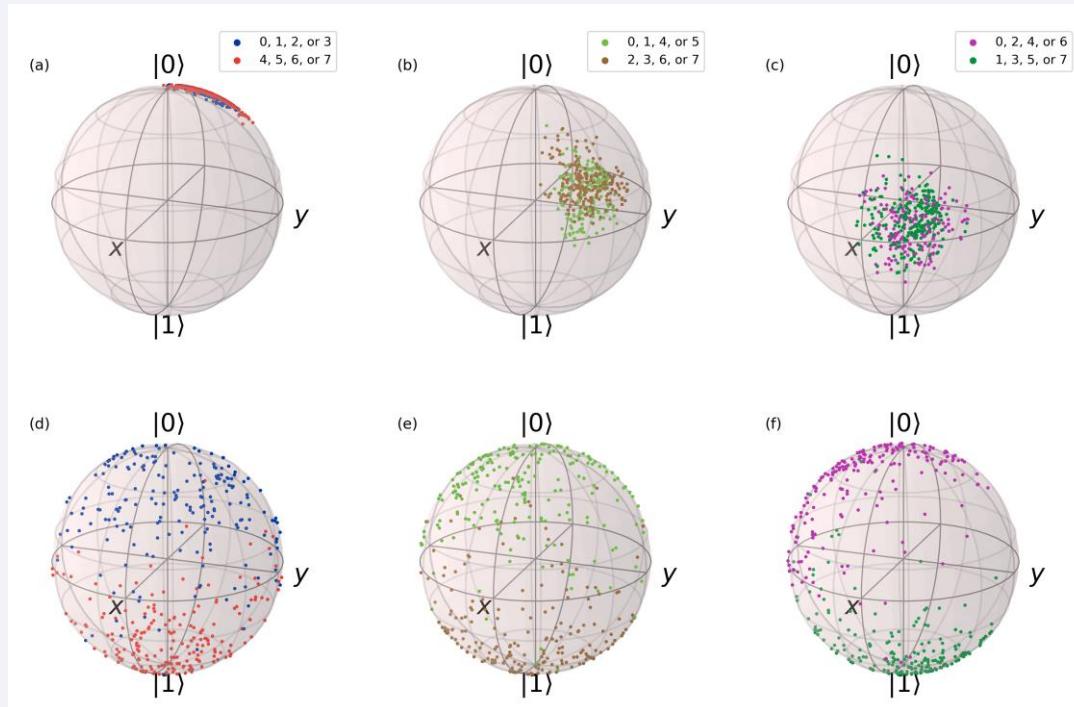
Pengklasifikasi DRC Representasi Biner dengan Reduksi PCA



Grafik nilai akurasi dan nilai biaya selama proses latih pada kombinasi reduksi PCA dengan pengklasifikasi DRC-RB untuk (a) klasifikasi 4 kelas (18 komponen prinsip, 4 lapisan) dan (b) klasifikasi 8 kelas (27 komponen prinsip, 4 lapisan).

Pengklasifikasi DRC Representasi Biner dengan Reduksi PCA 8 Kelas

Representasi *Bloch Sphere* untuk sampel data uji



Pengklasifikasi DRC Representasi Biner dengan Reduksi Konvolusi Kuantum (DRQConv) 2 Kelas

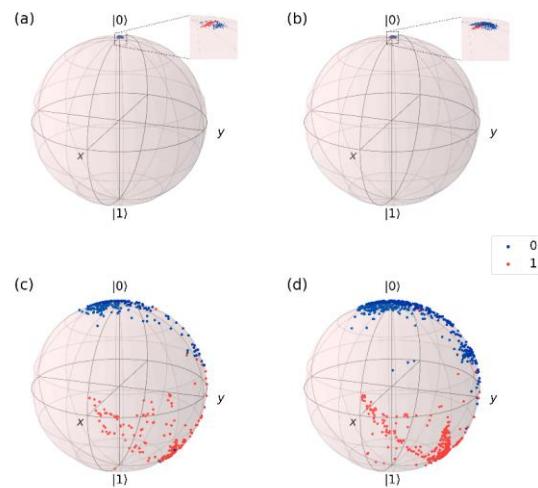
Sampel Data Latih:

- (a) Sebelum Training
- (c) Setelah Training

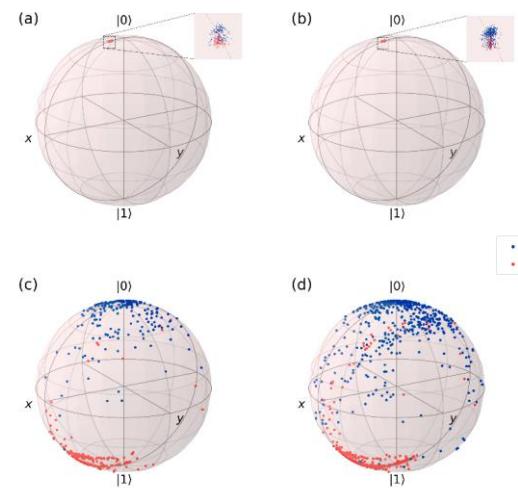
Sampel Data Uji:

- (b) Sebelum Training
- (d) Setelah Training

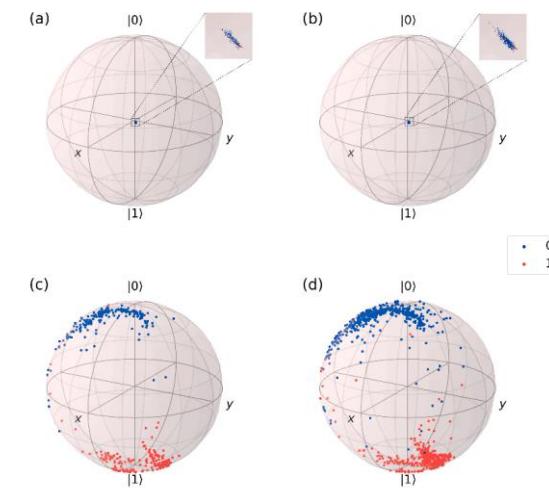
DRQConv I



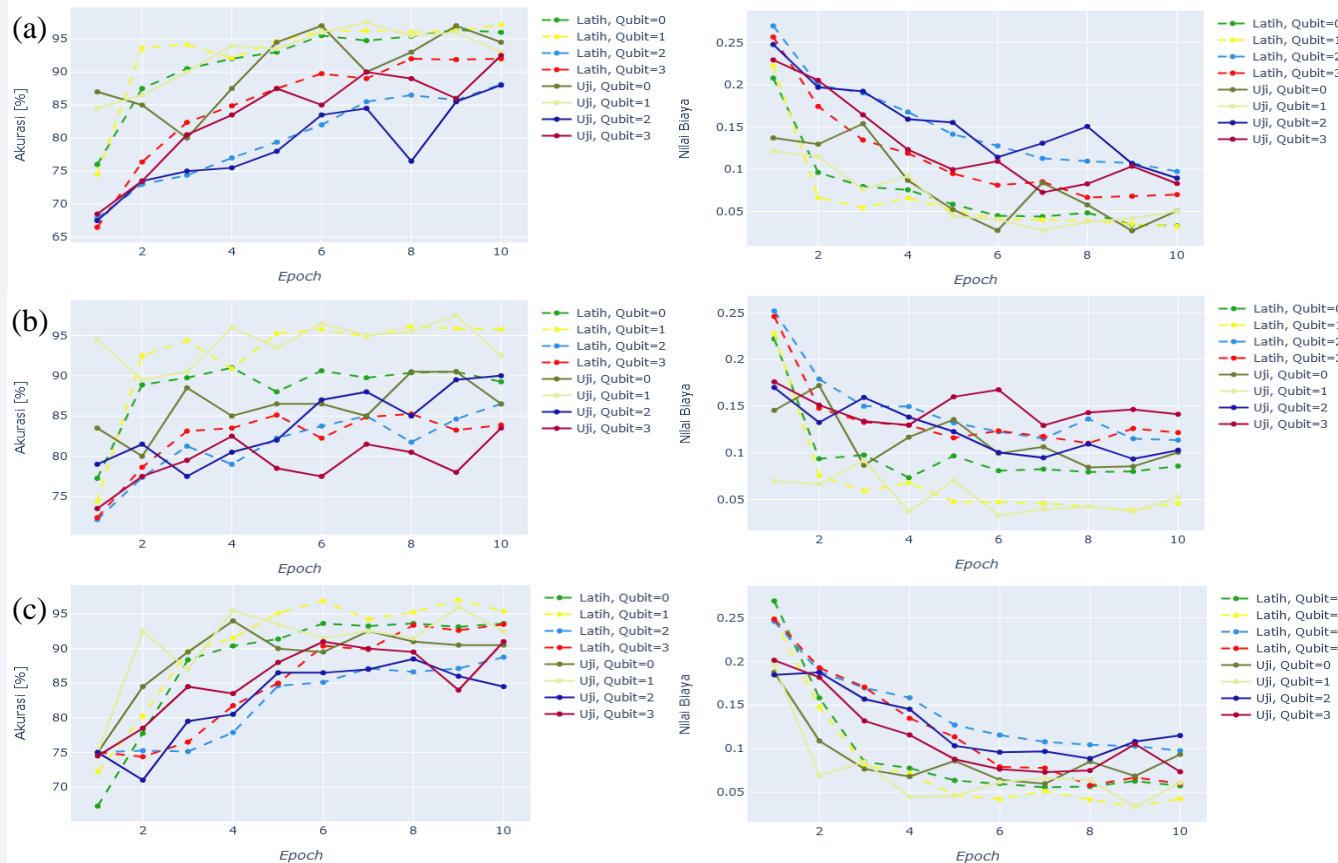
DRQConv II



DRQConv II + ent



Pengklasifikasi DRC Representasi Biner dengan Reduksi Konvolusi Kuantum (DRQConv): 4 Kelas



Grafik nilai akurasi dan nilai biaya selama proses latih pada kombinasi (a) DRQConv I, (b) DRQConv II, dan (c) DRQConv II + ent dengan pengklasifikasi DRC-RB untuk klasifikasi 4 kelas.